

Automatische bijsturing en spreiding van het elektriciteitsverbruik van ge- zinnen met behulp van artificiële intel- ligentie (AI).

Jan Tubeckx.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Dhr. F. Labijn
Co-promotor: Dhr. T. Tomme
Academiejaar: 2023–2024
Eerste examenperiode

Departement IT en Digitale Innovatie .



Woord vooraf

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Samenvatting

Door de omschakeling naar hernieuwbare energie wordt volop ingezet op elektrificatie. Dit vraagt enerzijds een modernisering van het distributienetwerk voor elektriciteit, maar ook de inzet van slimme technologieën om dit distributienetwerk te ontlasten. Een voorbeeld hiervan is de digitale elektriciteitsmeter die met behulp van allerhande apps 'slim' kan gemaakt worden en gezinnen zo meer inzicht kan geven in hun elektriciteitsverbruik zodat ze dit beter kunnen spreiden.

Dit onderzoek zal trachten te achterhalen hoe een app die een digitale elektriciteitsmeter aanstuurt kan geoptimaliseerd worden met behulp van artificiële intelligentie (AI). De meeste van de apps die momenteel bestaan geven immers enkel op een passieve manier weer wat het huidige verbruik en de huidige productie is. Er wordt van de verbruiker verwacht dat hij of zij op basis van deze inzichten de nodige acties onderneemt om het elektriciteitsverbruik bij te sturen. De Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG) (2021) heeft vastgesteld dat het slim maken van digitale elektriciteitsmeters voorlopig niet tot de gewenste gedragsverandering en spreiding van het elektriciteitsverbruik leidt.

In het eerste deel van het onderzoek zal worden nagegaan welke apps er reeds ontwikkeld werden en wat hun tekortkomingen zijn. Het verdere onderzoek zal vervolgens een app gaan ontwikkelen die met behulp van artificiële intelligentie en een weer API het elektriciteitsverbruik automatisch en dus actief zal bijsturen en spreiden. Meer concreet zal AI worden gebruikt om voorspellingen te doen op basis van historische zonnestralingsgegevens. Dit resultaat zal daarna verder verfijnd worden met weersvoorspellingen. De app zal op basis van de gecombineerde voorspellingen elektrische toestellen automatisch gaan in- of uitschakelen. Met deze bachelorproef zal in de eerste plaats geprobeerd worden om twee slimme stekkers aan te sturen. Deze stekkers kunnen via wifi en dus een app bediend worden. Op die manier kunnen sanitaire toestellen die zelf geen wifi-verbinding kunnen maken, toch 'slim' gemaakt worden. De gebruiker van de app zal wel steeds de mogelijkheid geboden worden om manueel tussen te komen.

Het verwachte resultaat is dat het elektriciteitsverbruik op die manier wel meer gestuurd en gespreid zal worden. Dit zal niet alleen tot een ontlasting van het distributienetwerk voor elektriciteit leiden, maar zal ook de energiekosten voor de gezinnen drukken.

Inhoudsopgave

Lijst van figuren	vii
1 Inleiding	1
1.1 Probleemstelling	1
1.2 Onderzoeksraag	4
1.3 Onderzoeksdoelstelling	4
1.4 Opzet van deze bachelorproef	5
2 Stand van zaken	6
2.1 Overzicht functionaliteiten bestaande apps	6
2.2 Voorspellingen maken met AI	7
2.2.1 Machine learning	7
2.2.2 Supervised machine learning: regressie modellen	9
2.2.3 Machine learning modellen evalueren	14
2.3 Elektriciteitsproductie voorspellen	15
2.3.1 Zonnestraling	16
2.3.2 Meteorologische data	17
2.4 Slimme toestellen aansturen	18
3 Methodologie	19
4 Proof of Concept	20
4.1 Ontwikkeling van de mobiele app	20
4.1.1 Digitale elektriciteitsmeter uitlezen	20
4.1.2 Omvormer zonnepanelen uitlezen	21
4.1.3 Stroomproductie van zonnepanelen voorspellen met XGBoost	22
4.1.4 Weergave uitgelezen data en voorspelling met een iOS app	31
4.1.5 Aansturing slimme apparaten op basis van de voorspelde stroomproductie	33
5 Conclusie	36
A Onderzoeksvoorstel	37
A.1 Inleiding	38
A.2 Literatuurstudie	41
A.3 Methodologie	44
A.4 Verwachte resultaten	45

Lijst van figuren

1.1	Verwachte evolutie van het aantal elektrische personenvoertuigen in Vlaanderen (Verdoodt, 2022)	2
1.2	Verwachte evolutie van het aandeel warmtepomp en -net bij residentiële verwarming in Vlaanderen (Verdoodt, 2022)	2
1.3	Verwachte evolutie van zonnepanelen in Vlaanderen (Verdoodt, 2022)	3
1.4	Verwachte evolutie van de elektrificatie van zwaar vachtvervoer in Vlaanderen (Verdoodt, 2022)	3
2.1	Grafische voorstelling beslissingsboom.	9
2.2	Grafische voorstelling van het Random Forest algoritme.	10
2.3	Grafische voorstelling Support Vector Machine.	11
2.4	Grafische voorstelling van het LSTM algoritme.	13
2.5	Grafische voorstelling van de structuur van het XGBoost algoritme.	14
4.1	Testopstelling: Raspberry Pi 5 via een RS422 serieel naar USB kabel aangesloten op een digitale elektriciteitsmeter.	21
4.2	Omvormer van de zonnepanelen met een wifi-stick.	22
4.3	Script voor het opvragen van de zonnestralingsdata.	24
4.4	Script voor het opvragen van de weerdata.	25
4.5	Heatmap van correlaties tussen de verschillende kenmerken van de dataset.	26
4.6	Screenshot van de Python code voor het aanmaken van features en lags.	27
4.7	Grafische voorstelling van de TimeSerieSplit functie.	28
4.8	Screenshot van de Python code voor de voorspelling van de zonnestraling van de volgende dag.	29
4.9	Overzicht elektriciteitsverbruik en -productie per dag en per week.	31
4.10	Voorspelling van de stroomproductie en overzicht van de ingeschakelde apparaten.	33
4.11	Screenshot van de Python code om de slimme stekker aan te sturen op basis van de voorspelde stroomproductie.	34
A.1	Verwachte evolutie van het aantal elektrische personenvoertuigen in Vlaanderen (Verdoodt, 2022)	38
A.2	Verwachte evolutie aandeel warmtepomp en -net bij residentiële verwarming (Verdoodt, 2022)	39

A.3 Verwachte evolutie PV (MWe) (Verdoodt, 2022).	39
A.4 Verwachte evolutie voor de elektrificatie zwaar vrachtvervoer (Verdoodt, 2022).	40

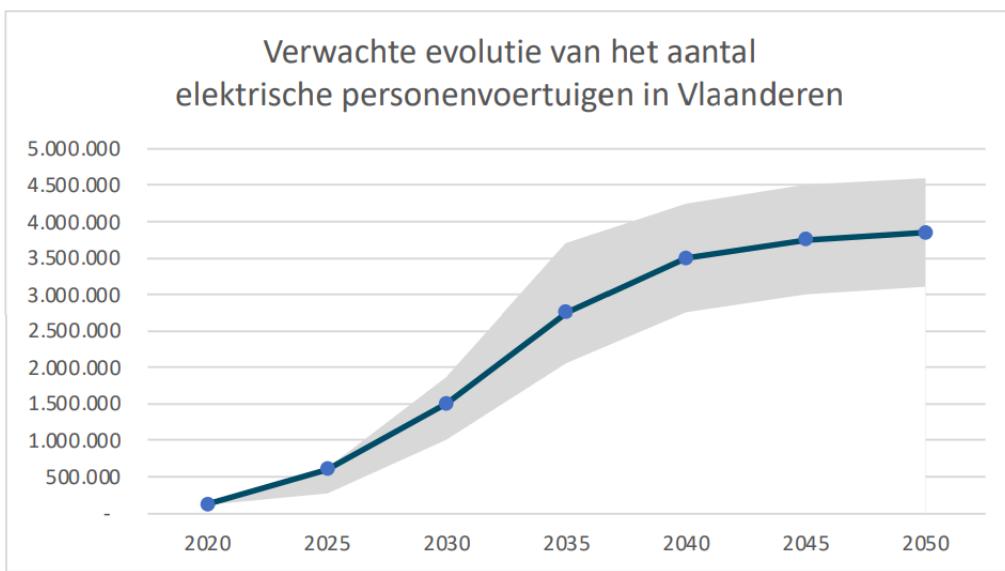
1

Inleiding

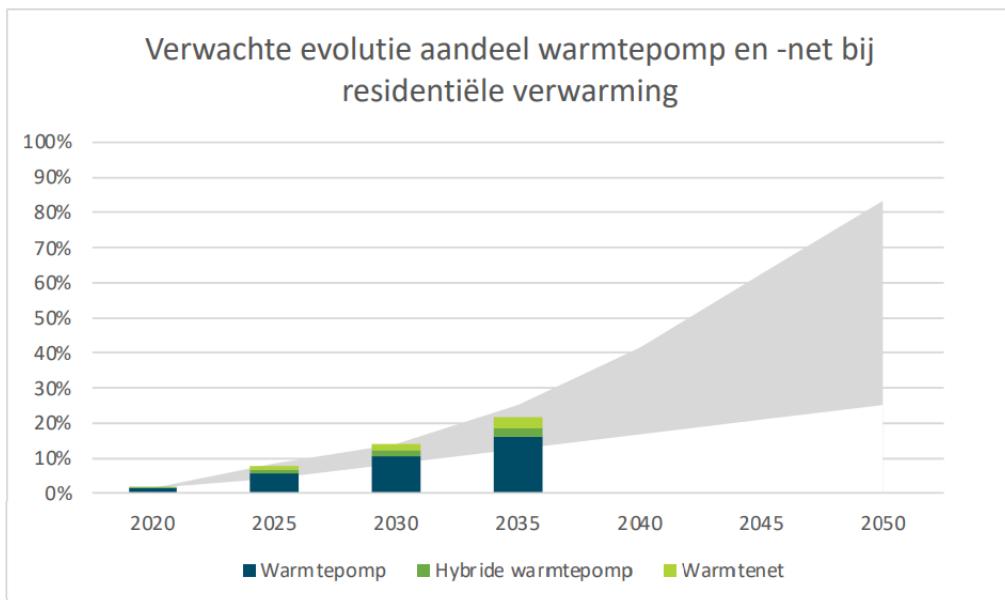
1.1. Probleemstelling

Anderhalf miljoen elektrische wagens, massaal veel warmtepompen en zonnepanelen gecombineerd met een toenemende elektrificatie van de industrie en het vrachtvervoer tegen 2030. Dat is de verwachting van de Vlaamse distributienetbeheerder Fluvius (Verdoodt, 2022). De energietransitie die vanuit Europa, België en Vlaanderen wordt aangestuurd, vormt een enorme uitdaging voor de distributienetten voor elektriciteit in Vlaanderen.

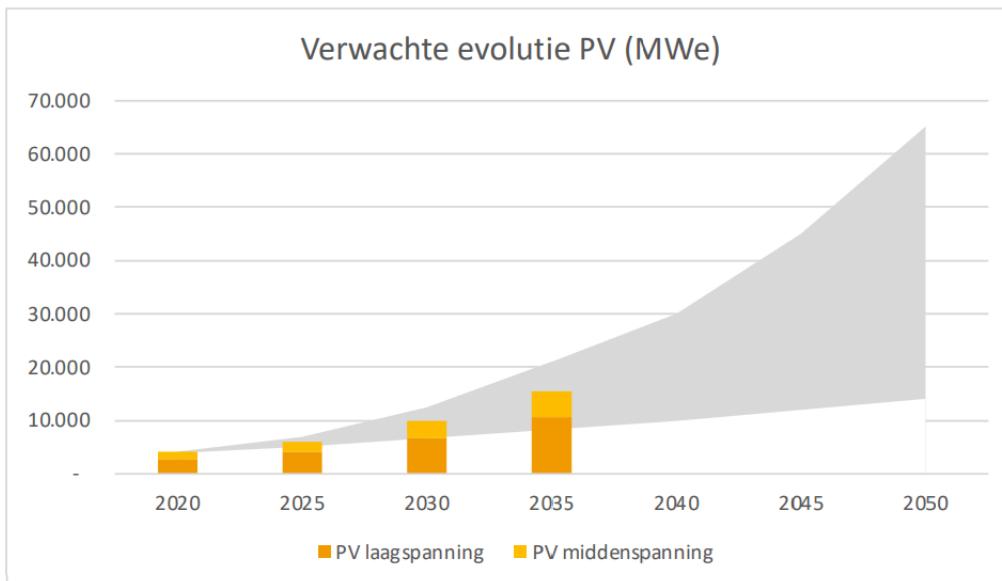
Om al te hoge investeringen in de distributienetten te vermijden, wordt door Fluvius ingezet op maatregelen die de belasting van het elektriciteitsnet kunnen verminderen en spreiden. Een van die maatregelen is de invoering en verplichting van de digitale elektriciteitsmeter. Tegen juli 2029 moeten alle Belgische huishoudens een digitale meter hebben. Deze digitale meters kunnen met behulp van apps 'slimmer' gemaakt worden. Zo kunnen gezinnen hun elektriciteitsverbruik in detail opvolgen en bijsturen wat hen meteen ook een besparing zal opleveren. Deze apps vereisen echter een actieve opvolging van de gebruiker. Die moet zelf toestellen in- of uitschakelen om het elektriciteitsverbruik bij te sturen. Uit onderzoek is echter gebleken dat deze actieve bijsturing na verloop van tijd vermindert (Wemyss e.a., 2019). Een enquête van de Vlaamse Regulator van de Elektriciteits- en Gasmarkt Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG) (2021) waarin 1.000 Vlaamse gezinnen en 1.500 bedrijven bevraagd werden over hun ervaring en gedrag op de energemarkt toont zelfs aan dat van de 60% van de gezinnen met een digitale meter, slechts 8% hun energieverbruik effectief bijstuurt. Door de invoering van het capaciteitstarief, een andere maatregel waarmee de VREG het elektriciteitsnet hoopt te onlasten, zal de bijsturing en vooral spreiding van het elektriciteitsverbruik evenwel nog belangrijker worden voor gezinnen. Sinds

**Figuur (1.1)**

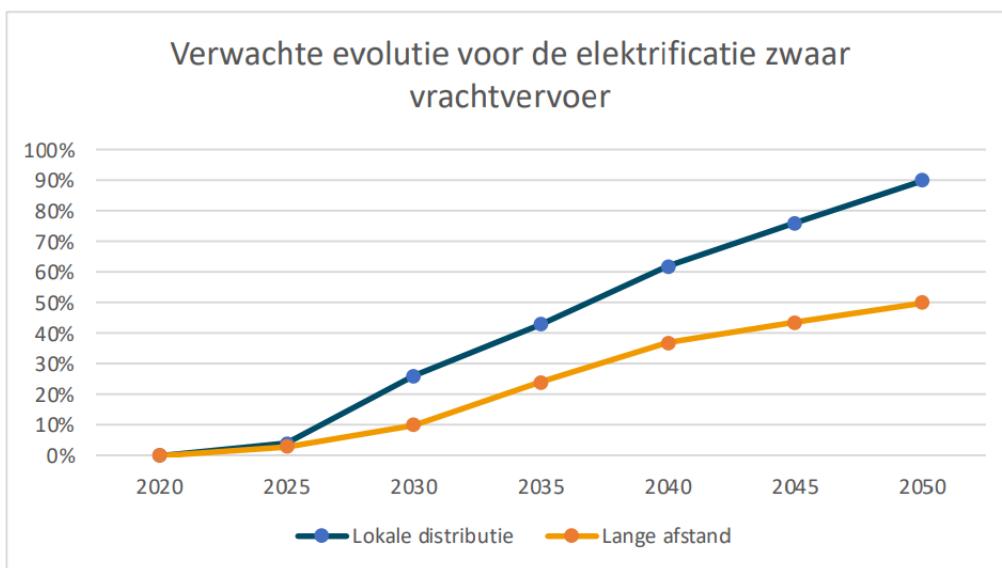
Verwachte evolutie van het aantal elektrische personenvoertuigen in Vlaanderen (Verdoodt, 2022).

**Figuur (1.2)**

Verwachte evolutie van het aandeel warmtepomp en -net bij residentiële verwarming in Vlaanderen (Verdoodt, 2022).

**Figuur (1.3)**

Verwachte evolutie van zonnepanelen in Vlaanderen (Verdoodt, 2022).

**Figuur (1.4)**

Verwachte evolutie van de elektrificatie van zwaar vrachtvervoer in Vlaanderen (Verdoodt, 2022).

1 januari 2023 wordt nameijk een deel van de nettarieven die een gezin via haar elektriciteitsfactuur betaalt ook berekend op het maximale elektriciteitsverbruik. Er wordt dus voortaan ook gekeken naar de maximale capaciteit die de distributienetbeheerders ter beschikking moeten stellen. Bedoeling van het capaciteitstarief is dat gezinnen hun stroomverbruik beter gaan spreiden. Als iedereen op hetzelfde moment veel stroom verbruikt, kan het net overbelast raken. Het gevolg is dat netbedrijven dan extra moeten investeren in zwaardere elektriciteitskabels om die hogere verbruikspieken op te vangen (Selleslagh, 2022).

Daarom wordt meer en meer de vraag gesteld hoe nieuwe technologieën en technieken een oplossing kunnen bieden om gezinnen te helpen bij het spreiden van hun elektriciteitsverbruik. Kunnen apps die het elektriciteitsverbruik monitoren slimmer gemaakt worden zodat ze geen tussenkomst van een gebruiker meer behoeven? Kan bijvoorbeeld artificiële intelligentie (AI) daarbij een oplossing bieden? Om dit na te gaan, zal tijdens dit onderzoek als proof of concept een app ontwikkeld worden die het elektriciteitsverbruik van gezinnen automatisch zal sturen met behulp van artificiële intelligentie.

1.2. Onderzoeksvoraag

Kan het elektriciteitsverbruik van gezinnen automatisch bijgestuurd en gespreid worden met behulp van artificiële intelligentie om zo de elektriciteitskost te drukken?

Kan een app die de stroomproductie van zonnepanelen voorspelt door toepassing van machine learning (ML) ervoor zorgen dat het elektriciteitsverbruik beter wordt afgestemd op de zelf geproduceerde stroom?

1.3. Onderzoeksdoelstelling

Om na te gaan of het elektriciteitsverbruik van een gezin automatisch kan gestuurd en gespreid worden, zal een app ontwikkeld worden die in de eerste plaats het elektriciteitsverbruik en de zelf geproduceerde stroom van zonnepanelen inzichtelijk maakt. Om het elektriciteitsverbruik en de geproduceerde stroom zo goed mogelijk op elkaar af te stemmen zal met behulp van machine learning de stroomproductie van de volgende dag voorspeld worden. Hiervoor zal gebruik gemaakt worden van historische zonnestralingsgegevens verkregen via de CAMS Radiation Service (CRS) van de Copernicus Atmosphere Monitoring Service (CAMS). Deze voorspelling zal verder verfijnd worden met de weersvoorspelling van de Open-Meteo weer API. De app zal vervolgens op basis van de gemaakte voorspellingen twee slimme stekkers gaan aansturen, zodat het elektriciteitsverbruik zo nauwkeurig mogelijk samenvalt met de voorspelde elektriciteitsproductie.

1.4. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt vooreerst een overzicht gegeven van de apps die er momenteel bestaan om een digitale elektriciteitsmeter slimmer te maken. Er zal kort worden ingegaan op de functionaliteiten die ze bieden om het elektriciteitsverbruik van gezinnen bij te sturen en wat hun tekortkomingen zijn. Vervolgens zal een vergelijking gemaakt worden van de verschillende machine learning modellen die kunnen gebruikt worden om voorspellingen te maken. Er wordt tevens een overzicht gegeven van de onderzoek die reeds verricht zijn naar de voorspelling van stroomproductie van zonnepanelen met behulp van machine learning en welke data hiervoor gebruikt kan worden. Als afsluiter wordt nog kort ingegaan op de aansturing van simme toestellen.

In Hoofdstuk 3 wordt de methodologie van deze bachelorproef toegelicht.

In Hoofdstuk 4 wordt de ontwikkeling van een app als proof of concept besproken. Er zal worden toegelicht hoe de stroomproductie van zonnepanelen kan voorspeld worden en hoe deze voorspellingen kunnen gebruikt worden om slimmer stekkers en toestellen aan te sturen. Met de ontwikkeling van deze app zal de onderzoeks-vraag proberen beantwoord worden.

In Hoofdstuk 5, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

Met een digitale elektriciteitsmeter kunnen gezinnen hun elektriciteitsverbruik makkelijk opvolgen. Dat kan in de eerste plaats gratis via het online energieportaal [Mijn Fluvius](#). Daarnaast bestaan er ook heel wat gratis of betalende online apps die met een digitale meter kunnen verbonden worden om elektriciteitsverbruik op te volgen en eventueel bij te sturen. Zo'n slimme toepassingen heten in het jargon 'HEMS' (Home Energy Management System) of 'CEMS' (Customer Energy Management System). De aansluiting van deze apps gebeurt via de gebruikerspoorten (P1 en S1) van de digitale elektriciteitsmeter. Beide gebruikerspoorten zijn complementair en geschikt voor verschillende toepassingen. De P1-poort stuurt de elektriciteitsdata per seconde uit. Via de 'snelle' S1-poort worden ruwe data aan een zeer hoge frequentie ter beschikking gesteld aan een app of slimme thermostaat. Dit laat gedetailleerde verbruikersfeedback en sturing toe. Recente digitale elektriciteitsmeters hebben evenwel geen S1-poort meer. De verbinding tussen het meettoestel en een app gebeurt in de meeste gevallen via een wifiverbinding of 4G. Een overzicht van deze toepassingen vindt men op de website [www.maakjemeterslim.be](#).

2.1. Overzicht functionaliteiten bestaande apps

De bestaande apps bieden allemaal de mogelijkheid om elektriciteitsverbruik in real time op te volgen. Zo kan de gebruiker per dag, per week of per maand na gaan hoeveel elektriciteit er verbruikt en/of geproduceerd werd. Het meten van de energiekosten per huishoudtoestel is ook meestal standaard voorzien, maar geldt even vaak als een optie. De meeste apps sporen ook sluipterverbruik op en bieden gepersonaliseerde tips voor energiebesparing. Sommige apps bieden tenslotte ook de mogelijkheid om het gemeten elektriciteitsverbruik naast weerdata te leggen en op die manier na te gaan hoeveel stroom men verbruikt bij bepaalde weersomstandigheden (Deman, 2021). Toen ik vorig jaar mijn onderzoeksvoorstel voor deze

bachelorproef formuleerde en uitschreef voor het vak 'Research methods' was er nog geen enkele app die de inzichten in het elektriciteitsverbruik gebruikte om automatisch apparaten aan te sturen. Het was toen aan de gebruiker zelf om op basis van de gegevens die de app hem toonde actie te ondernemen en toestellen te gaan in- of uitschakelen. Zoals reeds eerder werd vermeld, leidde dit niet altijd tot de gewenste gedragsverandering (Wemyss e.a., 2019), (Mack e.a., 2019) en (Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG), 2021). Ondertussen zijn een aantal apps daarom uitgebreid met de optie om (huishoud)apparaten automatisch in te schakelen via slimme stekkers. Zes apps voorzien momenteel in de optie om toestellen in te schakelen volgens elektriciteitstarieven of het overschat aan zelf geproduceerde stroom van zonnepanelen, daarbij telkens rekening houdend met het piekverbruik zodat een hoger capaciteitstarief vermeden wordt. Dit gebeurt met bijgeleverde slimme stekkers die via wifi kunnen aangestuurd worden. De automatische aansturing gebeurt echter steeds op het moment zelf, wanneer de app merkt dat er een overschat aan elektriciteitsproductie is of de elektriciteitsprijzen laag zijn. Tot op heden is er evenwel nog geen app die gebruik maakt van artificiële intelligentie om de zelf geproduceerde zonne-energie te voorspellen. Dit laat de gebruiker immers toe om de vaatwasser of wasmachine op voorhand in te laden, zodat de automatische aansturing ervan de volgende dag ook effectief kan gebeuren.

2.2. Voorspellingen maken met AI

Artificiële intelligentie (AI) verwijst naar de mogelijkheid van applicaties of machines om menselijke vaardigheden te tonen, zoals redeneren, leren en plannen. De term AI wordt vaak gebruikt om andere gerelateerde technieken aan te duiden, zoals machine learning (ML) en deep learning. ML en deeplearning kunnen inderdaad onder de verzamelnaam AI vallen, maar omgekeerd is dit niet altijd het geval. De verschillende technieken van AI hebben immers elk hun eigen doel en opzet. Zo is ML bijvoorbeeld gericht op de studie en de ontwikkeling van algoritmen die kunnen leren of hun prestaties kunnen verbeteren op basis van de data waarmee ze gevoed worden. Machine learning is daarom zeer geschikt om voorspellingen te maken op basis van data uit het verleden.

2.2.1. Machine learning

Machine learning kan opnieuw onderverdeeld worden in drie verschillende categorieën, namelijk supervised learning, unsupervised learning en reinforcement learning.

Supervised learning

Bij supervised machine learning wordt een algoritme door de mens aangeleerd welke conclusies het moet trekken. Er wordt daarbij gewerkt met gelabelde data, wat betekent dat voor elke invoer de gewenste uitvoer bekend is. Het doel van het

algoritme is om een model te bouwen dat de relatie tussen invoer en uitvoer begrijpt en deze kan toepassen op nieuwe, ongeziene gegevens. Indien een waarde of getal voorspeld wordt, spreekt men van een regressie. Heeft de voorspelling betrekking op een groep of categorie, dan is er sprake van classificatie (Brownlee, 2023).

Een voorbeeld van supervised learning is het voorspellen van huizenprijzen. Een model wordt daarbij getraind op een dataset van huizen waarvan de verkoopprijzen bekend zijn, samen met relevante kenmerken zoals locatie, grootte, aantal slaapkamers, enz. Het model leert vervolgens de relatie tussen deze kenmerken en de verkoopprijs van het huis. Als het model dan een nieuw huis met bijhorende kenmerken herkent, zal het de verkoopprijs ervan kunnen voorspellen.

Unsupervised learning

Unsupervised machine learning verloopt op een meer zelfstandige manier. Hierbij leert een algoritme om complexe processen en patronen te identificeren zonder de begeleiding van een mens. Bij unsupervised machine learning vindt training plaats op basis van data die geen labels of een specifieke, vooraf gedefinieerde output hebben (Brownlee, 2023).

Het misschien wel meest gekende voorbeeld van unsupervised learning zijn de aanbevelingen die streamingsplatformen zoals Netflix of Spotify aan hun kijkers aanbieden. Algoritmes analyseren het kijk- en luistergedrag van de gebruikers om daarin patronen en voorkeuren te ontdekken. Vervolgens kunnen dan gepersonaliseerde aanbevelingen gedaan worden.

Reinforcement learning

Bij reinforcement leert een algoritme of computersysteem hoe het moet handelen in een omgeving om een bepaald doel te bereiken. Dit gebeurt door het uitvoeren van acties en het ontvangen van feedback in de vorm van beloningen of straffen. Wat reinforcement learning specifiek maakt is dat het leerproces vergelijkbaar is met hoe een mens of dier zou leren door trial-and-error en beloningen (Efimov, 2024).

Reinforcement learning wordt gebruikt in robotica, bijvoorbeeld om robots autonom te laten navigeren in een omgeving. Om een robot obstakels te leren vermijden wordt gewerkt met beloningen en straffen. Voor elke correcte beweging richting het doel zal de robot een beloning ontvangen. Omgekeerd zal de robot bestraft worden voor elke incorrecte beweging die gemaakt wordt.

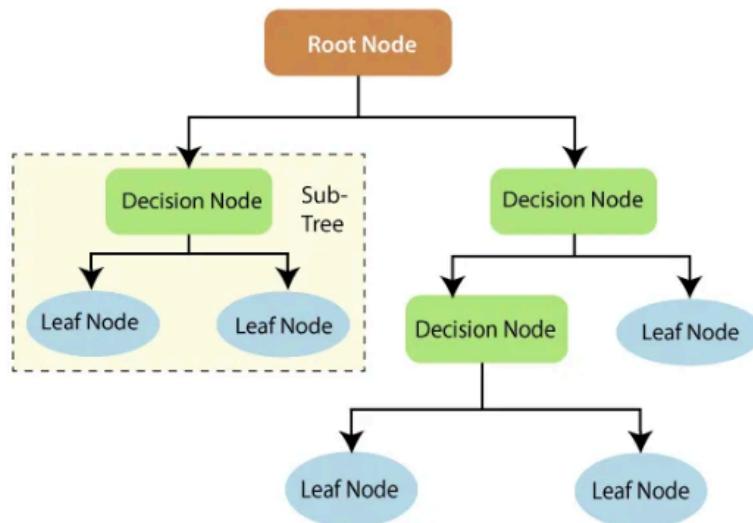
De applicatie die als proof of concept ontwikkeld wordt voor deze bachelorproef, zal de toekomstige stroomproductie van zonnepanelen gaan voorspellen. Hiervoor

zullen historische zonnestralingsgegevens gebruikt worden. Er zal dus gebruik gemaakt worden van de supervised learning methode en meer specifiek zal het regressiemodel toegepast worden. De waarde die moet voorspeld worden is de hoeveelheid zonnestraling uitgedrukt in Watt/m².

2.2.2. Supervised machine learning: regressie modellen

Decision Tree Regression (DTR)

Het Decision Tree model is een regressiealgoritme dat een dataset systematisch opdeelt in steeds kleinere homogene subgroepen op basis van de kenmerken van de gebruikte dataset. Het ontwikkelt daarbij een beslissingsboom, waarbij de interne knooppunten de kenmerken van de dataset vertegenwoordigen, de takken de beslissingsregels en elke bladknoop het resultaat. In de beslissingsboom zijn er twee knooppunten, namelijk de beslissingsknooppunten en de bladknooppunten. Beslissingsknooppunten worden gebruikt om een beslissing te nemen en hebben meerdere takken, terwijl Bladknooppunten de uitkomst van die beslissingen zijn en geen verdere takken bevatten. De beslissingen of de test worden uitgevoerd op basis van de kenmerken van de gegeven dataset. Het doel is om eenvoudige beslissingsregels te leren op basis van die specifieke kenmerken van de dataset om zo een model te ontwikkelen dat een bepaalde waarde voorspelt (Balakumar e.a., 2023).



Figuur (2.1)

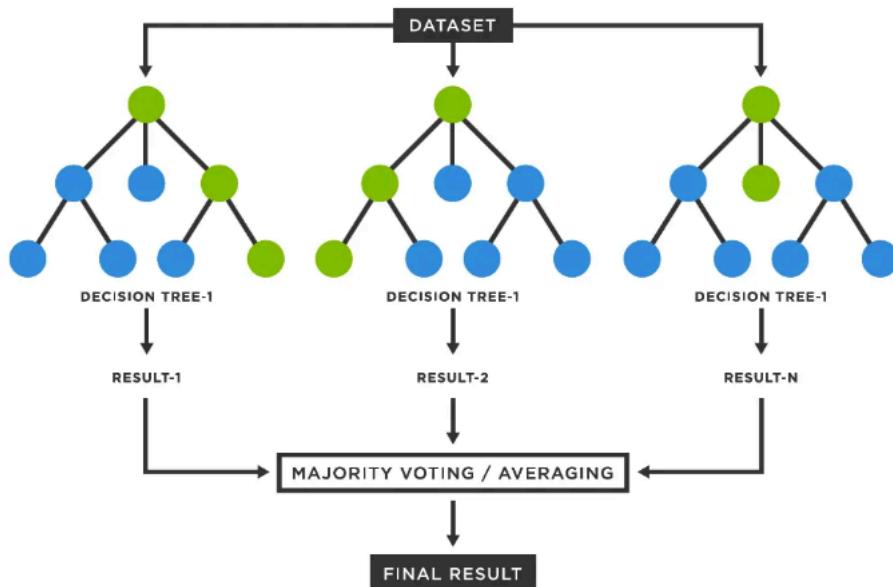
Grafische voorstelling beslissingsboom.

Decision trees zijn makkelijk te interpreteren omdat de geleerde beslissingsregels makkelijk te begrijpen en visualiseren zijn. Bovendien kan het DTR-algoritme niet-lineaire en dus meer complexe relaties tussen de inputvariabelen en de voorspelde

waarde ontdekken, wat het algoritme zeer bruikbaar maakt voor datasets die complexe patronen bevatten (Viswa, 2023).

Random Forest Regression (RFR)

Het Random Forest regressie model bestaat uit een verzameling van zogenaamde decision trees of beslissingsbomen. Een beslissingsboom is op zijn beurt een schema dat is opgebouwd uit een opeenvolging van binaire beslissingsregels. Het is een grafische voorstelling van een probleemstelling waarin verschillende mogelijke alternatieven met gebeurtenissen worden weergegeven en uitgewerkt. Het RFR-model maakt meerdere beslissingsbomen aan op basis van willekeurig gekozen subsets van de gebruikte dataset. Het model voegt vervolgens de uitkomsten van al deze beslissingsbomen samen om een algemene voorspelling te doen voor onbekende datapunten. Daarbij wordt telkens het gemiddelde of gewogen gemiddelde van elke beslissingsboom genomen. Op deze manier kan het grotere datasets verwerken en complexere verbanden vastleggen dan individuele beslissingsbomen. Het geheel van de voorspellingen van de beslissingsbomen zorgt voor een grotere accuraatheid dan de voorspelling van één enkele beslissingsboom. Over het algemeen kan gesteld worden dat hoe meer beslissingsbomen er in het RFR-model zitten, des te robuster het model zal zijn (Balakumar e.a., 2023).



Figuur (2.2)

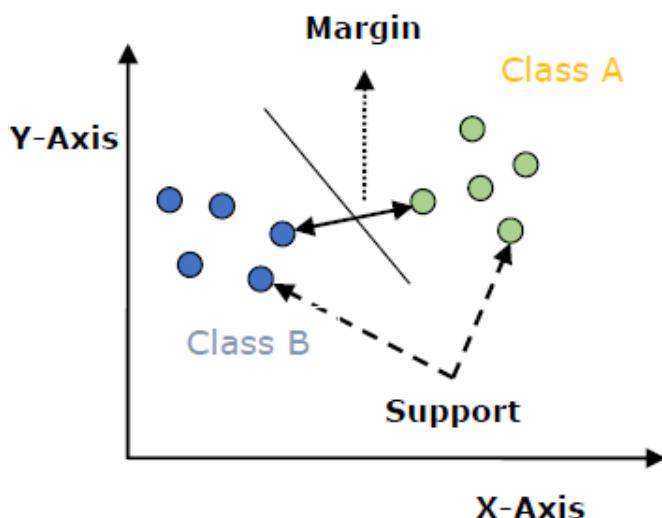
Grafische voorstelling van het Random Forest algoritme.

Het RFR-model wordt vaak gebruikt om continue waarden te voorspellen, zoals aandelenkoersen, tijdreeksen of verkoopprijzen. Het is minder gevoelig voor 'overfitting' (dit doet zich voor wanneer een ML-model de trainingsdata te goed leert, waardoor het nieuwe onbekende data slecht voorspelt) dan andere regressieme-

thoden omdat het meerdere willekeurige bomen onafhankelijk van elkaar opbouwt en een gemiddelde van de individuele voorspellingen neemt. Het is een goede keuze wanneer data gebruikt wordt met veel verschillende kenmerken of inputvariabelen (Sahai, 2023).

Support Vector Machine (SVM)

Het Support Vector Machine algoritme probeert data zo optimaal mogelijk in twee groepen te verdelen door het vinden van het beste hyperplane. Deze hyperplane is de meest optimale scheidingslijn tussen de twee groepen van data. Het algoritme maakt daarbij gebruik van support vectors. Dit zijn de datapunten die zich het dichtst bij de optimale scheidingslijn bevinden. Om de meest optimale scheidingslijn te achterhalen, berekent het algoritme de maximale marge of afstand tussen de datapunten van de twee groepen (Tziolis e.a., 2024). Omdat het algoritme zeer effectief is in het oplossen van complexere, niet-lineaire problemen, is het een model dat vaak gebruikt wordt om voorspellingen te maken op het gebied van hernieuwbare energie (Ahmad e.a., 2018).



Figuur (2.3)

Grafische voorstelling Support Vector Machine.

Het SVM-model wordt typisch gebruikt voor kleinere datasets omdat de trainigstijd van dit algoritme zeer lang kan zijn. Het wordt ook vooral toegepast op 'proper' datasets, dit zijn datasets die weinig afwijkingen of fouten bevatten.

Autoregressive Integrated Moving Average (ARIMA)

Het Autoregressive Integrated Moving Average (ARIMA) model is een populair voorspellingsmodel voor tijdreeksen. Het wordt veel gebruikt op verschillende gebieden om toekomstige waarden te analyseren en te voorspellen op basis van waar-

nemingen uit het verleden in een tijdreeksdataset.

Het ARIMA-model combineert drie belangrijke componenten: Autoregressie (AR), differentiëren (I) en voortschrijdend gemiddelde (MA).

AR - Autoregressief (p): Dit verwijst naar de afhankelijkheid van de huidige waarde in een tijdreeks van eerdere waarden. De volgorde van de AR-component, aangeduid met p, vertegenwoordigt het aantal vertraagde waarnemingen die in het model worden gebruikt.

I - Integratievevolgorde (d): Dit is het aantal verschillen dat we beschouwen tussen de huidige waarde en de waarde in het verleden om de tijdreeks stationair te maken. Stationair betekent dat de statistische eigenschappen van de reeks, zoals gemiddelde en variantie, constant blijven in de tijd.

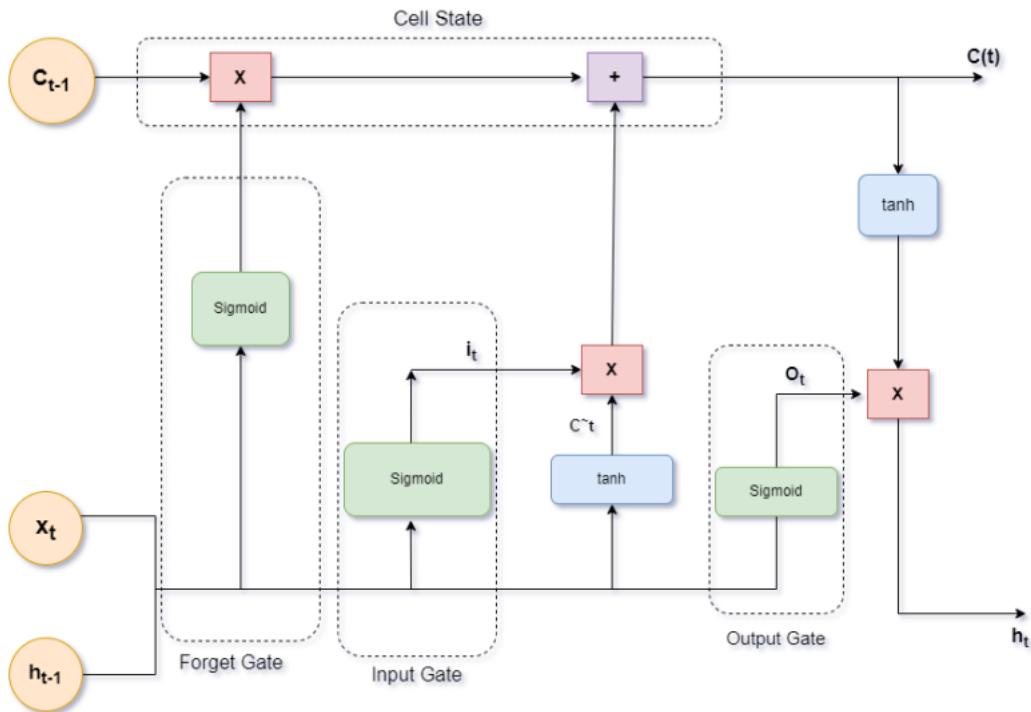
MA - Bewegend gemiddelde (q): Het vertegenwoordigt de afhankelijkheid tussen de huidige waarde en de restfouten van voorspellingen uit het verleden. Het berekent het gewogen gemiddelde van de vorige voorspellingsfouten. De volgorde van de MA-component, aangeduid met q, geeft het aantal vertraagde voorspellingsfouten weer die in het model worden gebruikt.

Long Short-Term Memory (LSTM)

Het Long Short-Term Memory (LSTM) is een type Recurrent Neural Network (RNN) dat wordt gebruikt om temporele afhankelijkheden in gegevens te modelleren. Concreet kan het zich gebeurtenissen uit het verleden of afhankelijkheden uit eerder waargenomen periodes herinneren.

Een LSTM is een type netwerk dat speciaal is ontworpen om een computer te helpen informatie langer te onthouden dan gewoonlijk mogelijk is met een terugkerend neuraal netwerk. Het lange-kortetermijngeheugenmodel werkt met behulp van 'cellen' die informatie gedurende langere tijd opslaan; wanneer een nieuwe invoer wordt gedetecteerd, worden er nieuwe cellen gemaakt die aan de bestaande cellen worden gekoppeld. Daarnaast kunnen de nieuwe cellen een deel van de informatie die in de bestaande cellen is opgeslagen 'vergeten', waardoor het netwerk een deel van wat het heeft geleerd kan 'vergeten'.

De belangrijkste componenten van de LSTM zijn de geheugencellen, vergeetpoorten en invoerpoorten. Geheugencellen zijn verantwoordelijk voor het langdurig opslaan van informatie, en de vergeet- en invoerpoorten beslissen welke informatie wel of niet in de cellen moet worden opgeslagen. Deze componenten zorgen ervoor dat LSTM-netwerken het verleden kunnen 'herinneren' en tegelijkertijd rekening kunnen houden met nieuwe input.

**Figuur (2.4)**

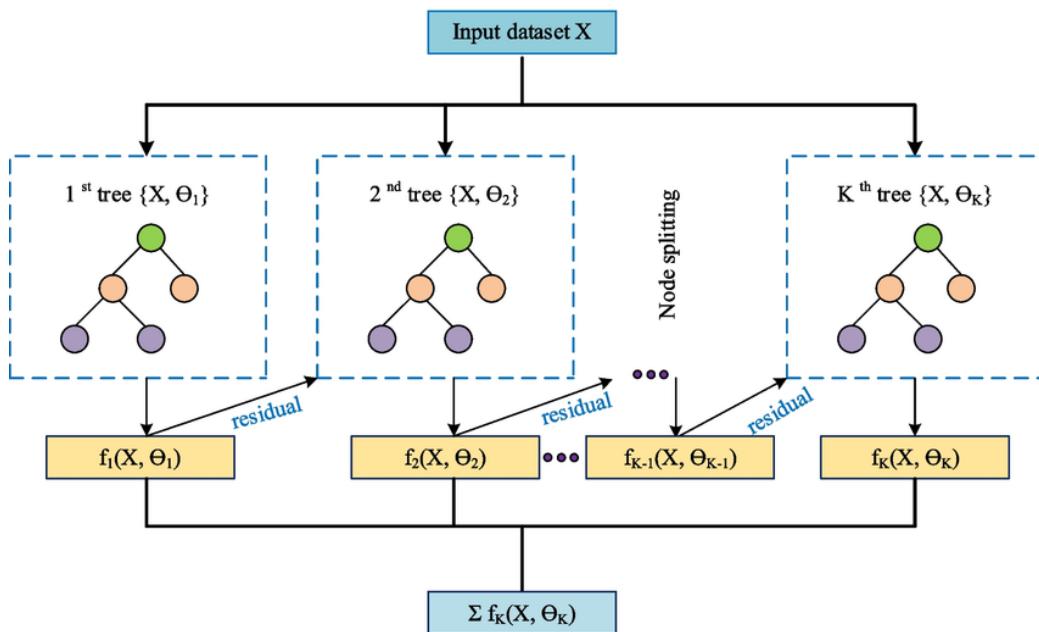
Grafische voorstelling van het LSTM algoritme.

LSTM's zijn zeer effectief vanwege hun vermogen om informatie gedurende langere tijd op te slaan en nieuwe input efficiënter te verwerken dan traditionele terugkerende neurale netwerken.

Extreme gradient Boosting (XGBoost)

Het XGBoost algoritme is een ensemble-leermethode die gradiëntversterking en beslissingsbomen combineert. Het concept van gradiëntversterking verwijst naar het opeenvolgend toevoegen van beslissingsbomen aan het model, waarbij elke volgende boom de fouten corrigeert die door de vorige zijn gemaakt. Dankzij dit iteratieve proces kan het XGBoost zijn voorspellingen voortdurend verbeteren en een hoge nauwkeurigheid bereiken. De werking van beslissingsbomen is hierboven reeds toegelicht.

Het XGBoost-model is een open-source implementatie van het gradient boosting algoritme. Het is specifiek ontworpen om de eigen prestaties te optimaliseren en

**Figuur (2.5)**

Grafische voorstelling van de structuur van het XGBoost algoritme.

grootschalige datasets efficiënt te verwerken. Door iteratief zwakke voorspellingen toe te voegen, kan het XGBoost algoritme snelle en accurate voorspellingen maken. Het grote voordeel van XGBoost is dat het ingebouwde mechanismen heeft om ontbrekende waarden in de dataset te verwerken. Het kan tijdens het trainingsproces automatisch leren hoe er het beste met ontbrekende waarden kan worden omgegaan. Vermits de meeste datasets uit de echte wereld gegevens ontbreken, is het XGBoost algoritme dus zeer geschikt om voorspellingen te maken. Nog een voordeel van het XGBoost-model is dat het makkelijk schaalbaar is, omdat het gebruik maakt van parallelle verwerkingstechnieken waarbij de werklast over meerdere cores of machines verdeeld wordt. Dit maakt snellere trainings- en voorspellingstijden mogelijk. Deze schaalbaarheid maakt XGBoost geschikt voor toepassingen die realtime voorspellingen vereisen.

2.2.3. Machine learning modellen evalueren

Om een machine learning model te beoordelen wordt de dataset waarmee het model getraind wordt, opgesplitst in een trainingset en een testset. Daarbij wordt de trainigset gebruikt om het model te trainen en wordt de testset gebruikt om de accuraatheid van de voorspellingen van het model te verifiëren. Er bestaan verschillende methodes waarmee de kwaliteit en nauwkeurigheid van een machine learning model kan gemeten worden. De meest gebruikte zijn:

Mean absolute error (MAE)

De Mean Absolute Error (MAE) of gemiddelde absolute fout is het gemiddelde van alle absolute voorspellingsfouten waarbij de voorspellingsfout het verschil is tussen

de werkelijke en de voorspelde waarde. Het wordt berekend door de absolute verschillen tussen voorspelde waarden en werkelijke waarden bij elkaar op te tellen en te delen door het aantal waarnemingen. Door de absolute waarde van voorspellingsfouten te gebruiken wordt voorkomen dat positieve en negatieve fouten elkaar opheffen. Hoe kleiner de waarde van de MAE, des te beter de voorspellingen van een model overeenstemmen met de werkelijke waarden.

Mean Squared Error (MSE)

Mean Squared Error (MSE) of gemiddelde kwadratische fout is de gemiddelde kwadratische afwijking tussen de voorspelde waarden van een model en de werkelijke waarden. Een lagere MSE geeft aan dat de voorspellingen van een model dichter bij de werkelijkheid liggen en het model dus nauwkeuriger is.

Root mean squared error (RMSE)

Root Mean Squared Error (RMSE) of vierkantswortel van de gemiddelde kwadratische fout is de gemiddelde omvang van de positieve of negatieve verschillen tussen de waarden die door een model voorspeld zijn en de geobserveerde (feitelijke) waarden. Het kan beschouwd worden als de standaardafwijking van de voorspellingsfouten.

RMSE biedt één enkele waarde die de prestaties van een model vertegenwoordigt, waardoor een eenvoudige vergelijking tussen verschillende modellen of voorspellingstechnieken mogelijk is. Lagere RMSE-waarden duiden op betere modelprestaties. Een lagere RMSE geeft aan dat de voorspellingen van het model dichter bij de werkelijke waarden liggen, wat een hogere nauwkeurigheid suggereert.

R-squared (R^2)

De R-squared (R^2) of determinatiecoëfficiënt meet in hoeverre een model in staat is een bepaalde uitkomst te voorspellen. Het geeft aan hoe sterk het verband is tussen de werkelijke waarden en de voorspelde waarden van een model. R^2 is dan ook nauw verwant aan de correlatiecoëfficiënt. Het kwadraat van de correlatiecoëfficiënt tussen de onafhankelijke en afhankelijke variabelen is gelijk aan de R-kwadraatwaarde. Dit impliceert dat een hogere correlatie overeenkomt met een hogere R-kwadraatwaarde.

De laagst mogelijke waarde van R^2 is 0 en de hoogst mogelijke waarde is 1. Hoe beter een model is in het maken van voorspellingen, hoe dichter de determinatiecoëfficiënt R^2 bij het getal 1 zal liggen.

2.3. Elektriciteitsproductie voorspellen

Doordat het belang van hernieuwbare energie de laatste jaren enorm is toegenomen, is er al heel wat onderzoek verricht naar het voorspellen van de toekom-

stige stroomproductie van zonnepanelen met behulp van machine learning. In de meeste van deze onderzoeken wordt deze voorspelling gebaseerd op de voorspelling van de hoeveelheid zonnestraling.

Alle onderzoeken opsommen en kort vermelden hoe en wat onderzocht wordt.

Een andere optie bestaat erin om de historische stroomproductie van de zonnepanelen te gaan analyseren en daaruit een voorspelling te gaan maken (Wang e.a., 2022). Deze historische stroomproductie data is evenwel niet altijd voldoende vorhanden, zodat het soms niet mogelijk is om op basis daarvan voorspellingen te gaan doen.

2.3.1. Zonnestraling

Vermits zonnepanelen zonne-energie omzetten in elektriciteit, is het bijna een logische keuze om de toekomstige stroomproductie van zonnepanelen te gaan voorspellen op basis van de voorspelling van de hoeveelheid zonnestraling (Ledmaoui e.a., 2023). Meestal wordt daarbij de inkomende of globale horizontale instraling (GHI, Global Horizontal Irradiance) voorspeld. GHI is de totale hoeveelheid zonnestraling die het aardoppervlak bereikt en wordt uitgedrukt in W/m². De GHI bestaat uit directe normale instraling (DNI, Direct Normal Irradiance) en de diffuse horizontale instraling (DHI, Diffuse Horizontal Irradiance). DNI verwijst naar de grootste directe (90 graden) neerwaartse zonnestraling voor een bepaalde plaats. Deze directe normale instraling wordt gebruikt om de diffuse horizontale instraling te berekenen. De DHI is de zonnestraling die niet rechstreeks van de zon komt, maar verspreid is door de wolken en deeltjes in de atmosfeer. Deze zonnestraling komt in gelijke mate uit alle richtingen (Sehrawat e.a., 2023).

Historische data met betrekking tot zonnestraling kan vrij verkregen worden via de CAMS Radiation Service (CRS) van de Copernicus Atmosphere Monitoring Service ([CAMS](#)). Dit maakt deel uit van het European Earth observation programme Copernicus (EEC) dat informatiediensten biedt op basis van aardobservatiegegevens van satellieten en in-situ gegevens (niet uit de ruimte). Enorme hoeveelheden wereldwijde gegevens van satellieten en van meetsystemen op de grond, in de lucht en op zee worden gebruikt om informatie te verstrekken aan dienstverleners, overhedsinstanties, andere internationale organisaties en burgers. De aangeboden informatiediensten zijn gratis en open toegankelijk voor de gebruikers ervan. De geografische dekking van de gegevens is het gebied dat door de Meteosat (een serie geosynchrone weersatellieten van de Europese ruimtevaartorganisaties ESA en EUMETSAT) kan worden waargenomen. Dit gebied omvat Europa, Afrika en het Midden-Oosten.

2.3.2. Meteorologische data

De hoeveelheid stroom die zonnepanelen produceren is niet enkel afhankelijk van de hoeveelheid zonnestraling. Ook andere meteorologische gegevens spelen hierbij een rol. Zo zijn de temperatuur, de relatieve luchtvochtigheid en de bewolkingsgraad factoren die het meeste invloed hebben op de stroomproductie van zonnepanelen (Sehrawat e.a., 2023).

Er zijn verschillende kanalen waarlangs historische weerdata kan verkregen worden. Zo zijn er datasets van meteorologische gegevens die door het Koninklijk Meteorologisch Instituut (KMI) beschikbaar gesteld worden. Het aantal datasets is echter zeer beperkt en moeten handmatig gedownload worden. Met het oog op de latere integratie van deze data in een app, is dit niet de meest ideale manier. Een andere optie is het CAMS. Ook daar kan historische weerdata voor een specifieke locatie opgevraagd worden, maar deze data is evenzeer beperkt aangezien de meest recente weerdata dateert van 2016.

Er bestaan tal van open source en dus gratis weer API's die makkelijk geïntegreerd kunnen worden met een app. Deze API's bieden voorspellingen aan van verschillende meteorologische gegevens, maar leveren vaak beperkte historische weerdata aan. Voor de historische weerdata werd [Meteostat](#) gekozen. Deze open-source API biedt een Python library waarmee met slechts een enkele HTTP-request historische weerdata voor een bepaalde locatie kan worden opgevraagd. Meteostat verzamelt historische weer- en klimaatdata van weerstations en verschillende nationale meteorologische instituten van over de hele wereld. De historische weerdata zal voor dezelfde periode als de zonnestralingsdata opgevraagd worden en op die manier de zonnestralingsdata verrijken, zodat de voorspelling van de toekomstige zonnestraling en stroomproductie van de zonnepanelen accurater wordt.

De voorspelling van de toekomstige elektriciteitsproductie van de zonnepanelen zal tenslotte nog proberen verbeterd worden door de voorspelde hoeveelheid zonnestraling te combineren met de weersvoorspellingen voor periode die voorspeld wordt. Omdat Meteostat enkel historische weerdata aanbiedt, werd voor de weersvoorspellingen een andere open-source weer-API gebruikt. [Open-Meteo API](#) werkt ook samen met verschillende nationale meteorologische diensten en biedt betrouwbare weersvoorspellingen aan tot 16 dagen in de toekomst. De aangeboden API-request kan makkelijk aangepast worden, zodat enkel de benodigde weerdata kan worden opgevraagd. Dit heeft een gunstig effect op de performantie bij het oproepen van de data.

2.4. Slimme toestellen aansturen

Om toestellen automatisch te kunnen inschakelen wanneer er voldoende elektriciteitsproductie van zonnepanelen is, moeten deze toestellen 'slim' zijn. Dit houdt in dat ze over een Soft Real Time Operating System (Soft RTOS) moeten beschikken en via het wifinetwerk kunnen communiceren. Laadpalen voor elektrische voertuigen en warmtepompen, maar ook de nieuwste was- en vaatwasmachines beschikken over deze technologie en kunnen via wifi communiceren. Zij kunnen dus zonder problemen via een app worden aangestuurd. Heel wat bestaande sanitaire toestellen zijn echter niet slim. Daarvoor kunnen slimme stekkers een oplossing bieden. Dit zijn stekkers die via wifi kunnen in- en uitgeschakeld worden. Zij worden tussen het klassieke stopcontact en de stekker van het toestel geplaatst, waardoor een toestel op een eenvoudige wijze slim kan gemaakt worden (de Jong, 2020). Daarbij stelt zich evenwel het probleem dat een slimme stekker enkel stroom kan doorlaten of tegenhouden. Dit vereist dat een toestel reeds kan ingeschakeld worden indien het geen stroom krijgt en dat het dus zonder tussenkomst van een gebruiker kan opstarten van zodra de slimme stekker stroom doorlaat. Omdat de huidige sanitaire toestellen meestal van stroom moet voorzien zijn om de startknop te activeren, bieden slimme stekkers dus niet altijd een oplossing.

Standaard communicatie protocol

Een bijkomend probleem dat zich stelt bij de aansturing van slimme toestellen is dat er geen standaard communicatieprotocol bestaat om deze toestellen te laten communiceren met een home energy management system (HEMS). Elke fabrikant gebruikt momenteel zijn eigen communicatieprotocol. Dit maakt dat applicaties die slimme apparaten willen aansturen, een verschillende implementatie per merk moeten voorzien. Het resultaat hiervan is dat een HEMS modelloos complex kan worden. Daarom wordt binnen Europa gepleit voor een gestandardiseerd communicatieprotocol. De S2 standaard biedt daarbij een oplossing, maar is tot op heden nog niet door Europa goedgekeurd (Konsman & Werkman, 2023).

3

Methodologie

Het onderzoek van deze bachelorproef bestaat uit twee delen. In het eerste deel wordt een literatuurstudie gemaakt om de huidige stand van zaken met betrekking tot het onderwerp van deze bachelorproef inzichtelijk te maken. Er wordt gestart met een overzicht van de functionaliteiten en tekortkomingen van de apps die er momenteel bestaan om een digitale elektriciteitsmeter slimmer te maken. Daarna wordt toegelicht hoe met behulp van AI en meer specifiek machine learning (ML) voorspellingen kunnen gemaakt worden. Er wordt daarbij kort ingegaan op de ML algoritmes die het vaakst gebruikt worden om zonnestraling en stroomproductie van zonnepanelen te voorspellen en hoe de prestaties van deze algoritmes kunnen beoordeeld worden. Vervolgens wordt een overzicht gegeven van de onderzoeken die reeds gevoerd zijn naar de voorspelling van zonnestraling en/of stroomproductie van zonnepanelen met behulp van machine learning. Daarbij wordt ook uitgelegd welke data hiervoor zal gebruikt worden in deze bachelorproef. De literatuurstudie wordt afgesloten met een toelichting over de aansturing van slimme apparaten en de problematiek van het ontbreken van een gestandardiseerd protocol hiervoor.

In het tweede deel van deze bachelorproef wordt de ontwikkeling van een proof of concept beschreven.

4

Proof of Concept

4.1. Ontwikkeling van de mobiele app

Om de onderzoeksvraag van deze bachelorproef te kunnen beantwoorden werden een Python web server en een iOS app ontwikkeld als proof of concept. Deze app maakt in de eerste plaats het elektriciteitsverbruik en de stroomproductie van de zonnepanelen inzichtelijk. Daarnaast zal de app via de toepassing van machine learning de elektriciteitsproductie van de volgende dag voorspellen. Deze voor-spelling zal dan door de app gebruikt worden om de inschakeling van twee slimme stekkers te programmeren indien er voldoende stroomproductie voorspeld wordt.

4.1.1. Digitale elektriciteitsmeter uitlezen

Een mobiele app die het elektriciteitsverbruik wil bijsturen en beter spreiden zal de gebruiker ervan allereerst inzicht moeten geven in zijn of haar verbruik. Om de verbruiksgegevens te ontsluiten moet de digitale elektriciteitsmeter uitgelezen worden via de P1-poort. Hiervoor zijn verschillende mogelijkheden, van een dongle tot kleine toestellen die via een kabel met de P1-poort kunnen verbonden worden. Voor dit onderzoek is er gekozen voor een Raspberry Pi 5 minicomputer om de digitale meter uit te lezen. Deze singleboardcomputer die gebaseerd is op een ARM processor en de Linuxdistributie Ubuntu als besturingssysteem heeft, biedt meer mogelijkheden dan enkel het uitlezen van data. Omdat het verbruik ervan zeer laag is, kan dit toestel bovendien continu ingeschakeld blijven. Daarnaast heeft de Raspberry Pi wifi-ondersteuning zodat deze kan verbonden worden met het wifi-netwerk van de woning die als testomgeving gebruikt wordt. Dit maakt het mogelijk om een webserver op te zetten en meteen ook de omvormer van de zonnepanelen van de woning via het wifi-netwerk uit te lezen met de Raspberry Pi (zie volgende sectie). In de testwoning bevindt de digitale elektriciteitsmeter zich namelijk in de kelder, terwijl de omvormer van de zonnepanelen zich op zolder be-

vindt. Een situatie die wel vaker voorkomt en op deze manier kan worden opgelost.



Figuur (4.1)

Testopstelling: Raspberry Pi 5 via een RS422 serieel naar USB kabel aangesloten op een digitale elektriciteitsmeter.

Opslag uitgelezen elektriciteitsdata

Nadat de Raspberry Pi via de juiste kabel op de P1-poort werd aangesloten, kon de data van de digitale elektriciteitsmeter via een Python script worden uitgelezen. Hiervoor werd een bestaand Python script uitgebreid (Depuydt, 2021). Het bestaande script voorzag enkel in het uitprinten van de uitgelezen data in de console. Om de uitgelezen elektriciteitsdata later via een app te kunnen weergeven moest deze data worden weggeschreven naar een databank. Omdat de data via de P1-poort per seconde uitgelezen wordt, werd geopteerd voor InfluxDB. Deze NoSQL-databank is speciaal ontwikkeld voor time-series en is binnen bepaalde (ruime) grenzen gratis te gebruiken (Balis e.a., 2017) en (Struckov e.a., 2019). Het Python script werd tenslotte opgezet als een achtergrond service via de systeem manager voor Linux 'systemctl/systemd', zodat het voortdurend blijft uitgevoerd worden.

4.1.2. Omvormer zonnepanelen uitlezen

Zoals reeds vermeld bevindt de omvormer van de zonnepanelen zich op de zolderverdieping, terwijl de Raspberry Pi zich in de kelder bij de digitale elektriciteitsme-

ter bevindt. De enige mogelijkheid om een draadloze verbinding te maken tussen beide toestellen is via het lokale wifi-netwerk. De omvormer in casu heeft echter geen ingebouwde wifi-ondersteuning en diende uitgebreid te worden met een aparte wifi-stick. Via deze wifi-stick kon dan vervolgens de data van de omvormer uitgelezen worden. Dit gebeurt opnieuw via een Python script waarin een request wordt gestuurd naar de server van de producent waar de gegevens van de omvormer worden bijgehouden. Omdat de data van de digitale elektriciteitsmeter per seconde wordt uitgelezen, wordt ook de data van de omvormer per seconde opgevraagd. De ontvangen gegevens zijn de temperatuur, de huidige geproduceerde stroom en de totale dagproductie van de zonnepanelen.



Figuur (4.2)

Omvormer van de zonnepanelen met een wifi-stick.

Ook de data van de omvormer worden via het Python script weggeschreven naar een aparte InfluxDB databank en opgezet als een achtergrond service via de systeem manager voor Linux 'systemctl/systemd'. Zo blijft ook dit script automatisch uitgevoerd worden.

4.1.3. Stroomproductie van zonnepanelen voorspellen met XGBoost

Het oorspronkelijke idee was om de stroomproductie van de zonnepanelen te gaan voorspellen op basis van de historische data van die stroomproductie. Voor dit onderzoek was er echter geen of slechts beperkte historische data vorhanden, omdat de metingen van de omvormer van de zonnepanelen pas gestart zijn bij het begin van het onderzoek. Na uitgebreid literatuuronderzoek werd beslist om de

stroomproductie van de zonnepanelen te gaan voorspellen op basis van de hoeveelheid zonnestraling (Sehrawat e.a., 2023), (Ledmaoui e.a., 2023), (Wang e.a., 2022) en (Sansine e.a., 2022). Via de CAMS Radiation Service (CRS) van de Copernicus Atmosphere Monitoring Service ([CAMS](#)) kan voldoende betrouwbare historische data met betrekking tot zonnestraling verkregen worden.

Historische zonnestralingsdata verzamelen

De zonnestralingsdata die via de CAMS Radiation Service (CRS) kan bekomen worden omvat tijdreeksen van globale, directe en diffuse insstraling voor een tijdsperiode van 1 februari 2004 tot en met 2 dagen geleden. De granulariteit van de data varieert van 1 maand tot 1 minuut en kan via een API-request opgevraagd worden.

Er bestaat een open-source Python library 'pvlib' (Jensen e.a., 2023) die ontwikkeld werd om de opbrengst van zonnepanelen te simuleren. Deze library bevat ook tools om zonnestralingsdata op te vragen, waaronder de data van de CAMS Radiation Service (CRS). Omdat de reeds ontwikkelde scripts voor het uitlezen van de digitale elektriciteitsmeter en de omvormer van de zonnepanelen in Python geschreven zijn, worden ook de andere scripts in Python geschreven en kan de pvlib-library dus gebruikt worden. Om de zonnestralingsgegevens op te vragen moeten een aantal parameters worden meegegeven, waaronder de locatie (lengte- en breedtegraad), de start- en einddatum en de tijdsgranulariteit. Omdat van de gebruiker van de app niet kan verwacht worden dat hij of zij de geografische coördinaten van zijn of haar woning kent, wordt de Python library Geopy gebruikt om het ingevoerde adres van een gebruiker om te zetten in de correcte lengte- en breedtegraad coördinaten en deze vervolgens mee te geven in de API-call naar de CRS.

Voor dit onderzoek wordt de zonnestralingsdata voor een periode van iets meer dan 5 jaar opgevraagd, van 1 januari 2019 tot op heden om precies te zijn. Dat heden is evenwel de datum van 2 dagen eerder, aangezien het 2 dagen duurt vooraleer de CRS de waargenomen zonnestralingsdata verwerkt en opgeslagen heeft. Dit geeft voldoende data om via een machine learning algoritme de toekomstige hoeveelheid zonnestraling te gaan voorspellen. Voor de granulariteit werd geopteerd voor metingen om de 15 minuten. Zo zijn de metingen van de bekomen dataset voldoende gedetailleerd om accurate voorspellingen te kunnen maken, zonder dat de performantie in het gedrang komt. Bij metingen van 1 minuut blijkt de dataset te omvangrijk om er op een efficiënte en dus snelle manier berekeningen op uit te voeren.

```

11 # Get solar irradiance data for specified address
12 # User input
13 user_address = 'Toekomststraat 67, 9040 Sint-Amandsberg'
14
15 # Determine coordinates of entered address
16 loc = Nominatim(user_agent="Geopy Library")
17 getLoc = loc.geocode(user_address, timeout=None)
18 latitude = getLoc.latitude
19 longitude = getLoc.longitude
20
21 # past_date = (datetime.now()-timedelta(365*5)).date()
22 past_date = '2019-1-1'
23 current_date = datetime.now().date()
24
25 # Get solar irradiance data from Copernicus Atmosphere Monitoring Service (CAMS)
26 data = pvlib.iotools.get_cams(latitude,
27                                longitude,
28                                start=past_date,
29                                end=current_date,
30                                email='jan.tubeeckx@hotmail.com',
31                                identifier='cams_radiation',
32                                time_step='15min',
33                                time_ref='UT',
34                                verbose=False,
35                                integrated=False,
36                                label=None,
37                                map_variables=True,
38                                server='api.soda-solaridata.com',
39                                timeout=30)

```

Figuur (4.3)

Script voor het opvragen van de zonnestralingsdata.

Weerdata

Niet alleen de hoeveelheid zonnestraling is bepalend voor de stroomproductie van zonnepanelen, ook de weersomstandigheden oefenen een invloed uit. Vooral de omgevingstemperatuur, de relatieve luchtvochtigheid en de bewolkingsgraad zijn factoren die de stroomproductie van zonnepanelen kunnen vergroten of verkleinen (Sehrawat e.a., 2023).

Om de voorspelling van de toekomstige stroomproductie van de zonnepanelen accurater te maken, zal de zonnestralingsdata in de eerste plaats gecombineerd worden met historische weerdata voor dezelfde periode, van 1 januari 2019 tot op heden. Ook hiervoor werd gezocht naar een open-source API, waarmee de data via een Python script kan worden opgevraagd. Finaal is voor Meteostat gekozen. Deze API biedt een Python library waarmee met slechts een enkele HTTP-request historische weerdata voor een bepaalde locatie kan worden opgevraagd. Meteostat verzamelt historische weer- en klimaatdata van weerstations en verschillende nationale meteorologische instituten van over de hele wereld. Omdat ook voor deze API-call de

lengte- en breedtegraad van de gevraagde locatie moet worden ingegeven, wordt opnieuw gebruik gemaakt van de Python library Geopy waarmee een adres kan worden omgezet in de correcte lengte- en breedgraad coördinaten.

```
4 import openmeteo_requests
5 from datetime import datetime
6 from retry_requests import retry
7 from geopy.geocoders import Nominatim
8 from meteostat import Point, Hourly
9
10 # User input
11 user_address = "Toekomststraat 67, 9040 Sint-Amandsberg"
12 gradient = 45
13 orientation = -135
14
15 # Determine coordinates of entered address
16 loc = Nominatim(user_agent="Geopy Library")
17 getLoc = loc.geocode(user_address, timeout=None)
18 latitude = getLoc.latitude
19 longitude = getLoc.longitude
20
21 # Set time period
22 current_date = datetime.now().date()
23 year = current_date.year
24 month = current_date.month
25 day = current_date.day
26 start = datetime(2019, 1, 1)
27 end = datetime(year, month, day)
28
29 location = Point(latitude, longitude)
30
31 # Get hourly historical weatherdata since the 1st january 2019
32 data = Hourly(location, start, end)
33 weather_data = data.fetch()
34 weather_data.drop(columns=['snow', 'wdir', 'wspd', 'wppt', 'tsun', 'coco'], inplace=True)
35 weather_data.rename(columns={'temp':'temperatuur', 'dwpt':'dauwpunt', 'rhum':'luchtvochtigheid',
36 'prcp':'neerslag', 'pres':'luchtdruk'}, inplace=True)
37 weather_data.index = pd.to_datetime(weather_data.index)
```

Figuur (4.4)

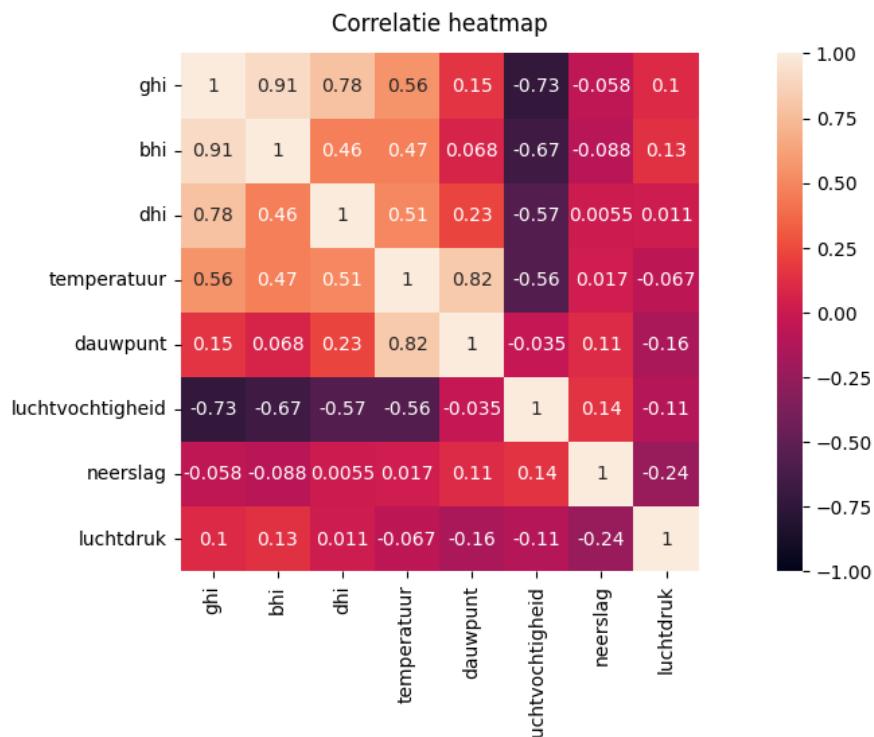
Script voor het opvragen van de weerdata.

Om de voorspelling van de stroomproductie van de zonnepanelen nog beter te maken, zal de bekomen voorspelling gecombineerd worden met de weersvoorspellingen voor de voorspelde periode. Aangezien Meteostat enkel historische data aanbiedt, moest een andere open-source weer-API gevonden worden. [Open-Meteo API](#) werkt ook samen met verschillende nationale meteorologische diensten waardoor het betrouwbare weersvoorspellingen aanbiedt. De aangeboden API-request is makkelijk in te stellen, zodat enkel de benodigde weerdata kan worden opgevraagd. Zo kan de data snel opgevraagd worden. Voor dit onderzoek worden enkel de voorspellingen van de omgevingstemperatuur, de relatieve luchtvochtigheid en de bewolkingsgraad opgehaald.

Voorspelling met XGBoost

Door het toenemend belang van hernieuwbare energie is er al heel wat onderzoek verricht naar het voorspellen van de elektriciteitsproductie van PV-systemen door toepassing van machine learning. Uit de meest recente onderzoeken blijkt dat Extreem Gradient Boosting (XGBoost) andere machine learning algoritmes overtreft bij het voorspellen van historische zonnestraling (Khasawneh e.a., 2024), (Tercha e.a., 2024), (Ledmaoui e.a., 2023), (Wang e.a., 2022) en (Barrera-Animas e.a., 2022). Om die reden wordt voor dit onderzoek gebruik gemaakt van XGBoost om de toekomstige zonnestraling en vervolgens de stroomproductie van zonnepanelen te voorspellen.

Data cleaning en correlaties De dataset die als invoer voor het XGBoost algoritme gebruikt werd, is dus een combinatie van historische zonnestralingsdata en weerdata. Deze dataset werd eerst gezuiverd van anomalieën door alle negatieve en ontbrekende waarden te verwijderen, anders zouden deze fouten de voorspelde waarden kunnen vertekenen. Na het opschonen van de data werden bestaande correlaties onderzocht. Hiervoor werd de Python library 'Seaborn' gebruikt, waar mee een heatmap van de correlaties tussen de verschillende kenmerken van de dataset kon worden opgemaakt. Daaruit blijkt inderdaad dat vooral de omgevingstemperatuur (positief) en luchtvochtigheid (negatief) het sterkst correleren met de globale horizontale insstraling van de zon (GHI).



Figuur (4.5)

Heatmap van correlaties tussen de verschillende kenmerken van de dataset.

Toevoeging van features De historische zonnestralingsdata die gebruikt wordt, kan beschouwd worden als tijdreeksen (time-series) vermits de data geordend is volgens een tijdsindex. Om de analyse van deze tijdreeksen te verbeteren en patronen in de zonnestralingsdata vast te stellen, worden extra 'Features' of tijdgerelateerde kenmerken toegevoegd aan de gebruikte dataset. Deze kenmerken worden afgeleid van de index van de dataset die uit het tijdstip van de gemeten waarde bestaat (zie figuur 4.6). Deze verrijking zorgt voor een beter begrip van de tijdsgebonden aspecten van de gegevens en het later toegepaste XGBoost model bij het herkennen van patronen en seizoensgebondenheid.

```
49 ## Apply feature engineering
50 # Create time series features based on time series index
51 def create_features(df):
52     df = df.copy()
53     df['hour'] = df.index.hour
54     df['dayofweek'] = df.index.dayofweek
55     df['quarter'] = df.index.quarter
56     df['month'] = df.index.month
57     df['year'] = df.index.year
58     df['dayofyear'] = df.index.dayofyear
59     df['dayofmonth'] = df.index.day
60     return df
61
62 historical_data = create_features(historical_data)
63
64 # Create lag features
65 def add_lag_features(df):
66     target_map = df[solar_irradiation].to_dict()
67     df['lag_1'] = (df.index - pd.Timedelta('24 hours')).map(target_map)
68     df['lag_2'] = (df.index - pd.Timedelta('48 hours')).map(target_map)
69     df['lag_3'] = (df.index - pd.Timedelta('72 hours')).map(target_map)
70     df['lag_4'] = (df.index - pd.Timedelta('7 days')).map(target_map)
71     df['lag_5'] = (df.index - pd.Timedelta('14 days')).map(target_map)
72     df['lag_6'] = (df.index - pd.Timedelta('364 days')).map(target_map)
73     return df
74
75 historical_data = add_lag_features(historical_data)
```

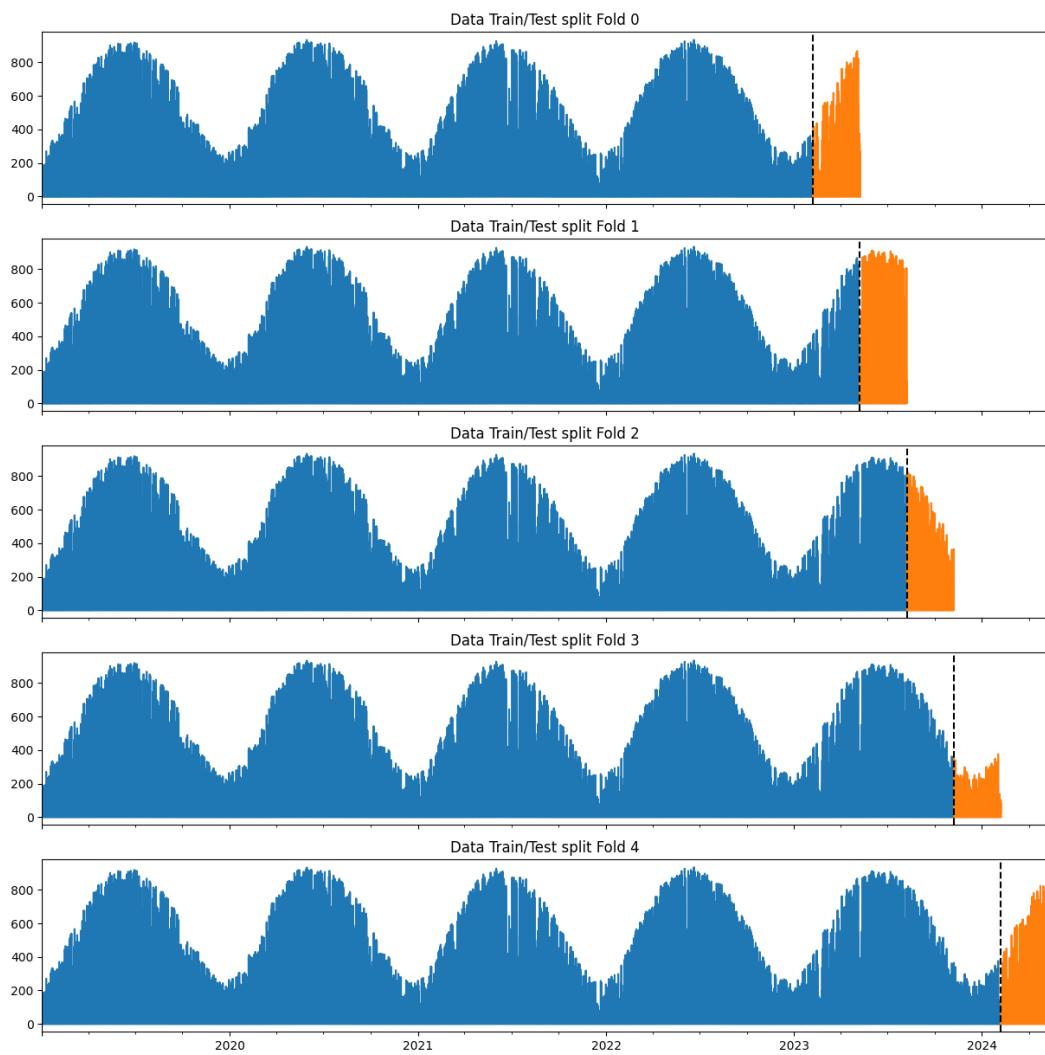
Figuur (4.6)

Screenshot van de Python code voor het aanmaken van features en lags.

Toevoeging van lag features Om het XGBoost algoritme nog beter in staat te stellen om tijdsgebonden afhankelijkheden en verbanden te herkennen, worden zogenaamde 'lag features' of vertragingskenmerken aan de dataset toegevoegd. Hiermee wordt het algoritme opgedragen om de zonnestralingswaarden van een bepaald aantal dagen in het verleden op te nemen als nieuwe features. De toevoeging van lag features zorgt opnieuw voor een verrijking van de dataset en voorziet het model van historische informatie om zonnestralingspatronen beter te begrijpen en te voorspellen, wat uiteindelijk bijdraagt aan de nauwkeurigheid en effectiviteit.

viteit van het XGBoost model (Nabatchian, 2024).

XGBoost model trainen en testen Omdat het XGBoost model heel wat parameters bevat die kunnen aangepast worden, werden verschillende versies ontwikkeld en getest. Om elke versie te kunnen beoordelen werd de gebruikte dataset opgesplitst in een trainingset en een testset. Daarbij werd het algoritme getraind op de trainigset en beoordeeld op testset. Omdat de data uit tijdreeksen bestaat, werd voor het opsplitsen van de dataset geopteerd voor de 'TimeSeriesSplit' functie van de Scikit-learn library. Deze functie is speciaal ontworpen voor de opsplitsing van tijdreeksgegevens en zorgt ervoor dat de chronologische volgorde van de gegevens behouden blijft tijdens het opsplitsingsproces. Dit zorgt voor een grotere nauwkeurigheid van de beoordeling van de voorspellingscapaciteit van het model.



Figuur (4.7)

Grafische voorstelling van de TimeSerieSplit functie.

Om de geteste modellen te beoordelen werd telkens de mean absolute error (MAE), mean squared error (MSE) en root mean squared error (RMSE) over de verschillende

opsplitsingen heen berekend. Het uiteindelijk gekozen model behaalde volgende scores: MAE score van 0.5519, MSE score van 1.5816 en RMSE score van 1.2576.

Voorspelling van de zonnestraling Om de toekomstige zonnestraling te voorspellen werd het geselecteerde algoritme getraind op de volledige dataset met alle historische data, zonder een opsplitsing te maken tussen een training- en testset. De bekomen voorspelling van de zonnestraling werd vervolgens gecombineerd met de voorspelling van de omgevingstemperatuur en de relatieve luchtvochtigheid die via de Open-Meteo API voor dezelfde periode werd opgehaald.

```

144 ## Make predictions
145 # Retrain data
146 df = create_features(historical_data)
147 df = add_lag_features(historical_data)
148
149 FEATURES = ['hour', 'dayofweek', 'quarter', 'month', 'year', 'dayofyear', 'dayofmonth',
150             'temperatuur', 'luchtvochtigheid', 'lag_1', 'lag_2', 'lag_3', 'lag_4', 'lag_5', 'lag_6']
151 TARGET = [solar_irradiation]
152
153 X_all = df[FEATURES]
154 y_all = df[TARGET]
155
156 xgb_model = xgb.XGBRegressor(learning_rate = 0.1,
157                                 n_estimators=5000,
158                                 max_depth=5,
159                                 min_child_weight=1,
160                                 gamma=0,
161                                 subsample=0.8,
162                                 colsample_bytree=0.8)
163
164 xgb_model.fit(X_all, y_all,
165                 eval_set=[(X_all, y_all)],
166                 verbose=100)
167
168 xgb.plot_importance(xgb_model)
169
170 current_date = solar_irradiance_df.index.max().date()
171 future_date = current_date+timedelta(nr_of_days_to_predict)
172 future = pd.date_range(str(current_date), str(future_date), freq='15min')
173 future_df = pd.DataFrame(index=future)
174 future_df['isFuture'] = True
175 df['isFuture'] = False
176 df_and_future = pd.concat([df, future_df])
177 df_and_future = create_features(df_and_future)
178 df_and_future = add_lag_features(df_and_future)
179 future_with_features = df_and_future.query('isFuture').copy()
180
181 # Predict future ghi
182 future_with_features[solar_irradiation] = xgb_model.predict(future_with_features[FEATURES])
183 future_with_features['solar_irr_prediction'] = future_with_features[solar_irradiation]
184
185 # Adjust prediction with hours in shade
186 future_with_features.loc[future_with_features.index.hour > 13,
187                         'solar_irr_prediction'] = future_with_features['solar_irr_prediction'] * 0.7
188 future_with_features.loc[future_with_features.index.hour < 7, 'solar_irr_prediction'] = 0
189 future_with_features.loc[future_with_features.index.hour > 20, 'solar_irr_prediction'] = 0
190 future_with_features.loc[future_with_features['solar_irr_prediction'] < 0, 'solar_irr_prediction'] = 0
191 future_with_features.drop(columns=['hour', 'dayofweek', 'quarter', 'month', 'year', 'dayofyear',
192                                     'dayofmonth', 'temperatuur', 'luchtvochtigheid', 'lag_1', 'lag_2',
193                                     'lag_3', 'lag_4', 'lag_5', 'lag_6', 'ghi', 'dhi', 'bhi'], inplace=True)
194
195 # Combine time series forecast with weather forecast for most important parameters
196 prediction = future_with_features.join(weather_forecast)
197 # prediction.index = prediction.index - timedelta(hours=1)
198 prediction['final_prediction'] = (prediction['solar_irr_prediction'] *
199                                     (prediction['temperature_2m'].div(10)) /
200                                     (prediction['relative_humidity_2m'].div(100))) * 0.5

```

Figuur (4.8)

Screenshot van de Python code voor de voorspelling van de zonnestraling van de volgende dag.

Omzetting voorspelde zonnestraling naar opgewekte stroom Op basis van de gecombineerde voorspelling van de zonnestraling (GHI) kan vervolgens de toekomstige stroomproductie van de zonnepanelen berekend worden. Daarbij geldt dat het opgewekte vermogen van zonnepanelen lineair toeneemt naarmate de zonnestraling (GHI) toeneemt, en lineair afneemt naarmate de omgevingstemperatuur toeneemt. Het opgewekte vermogen van de zonnepanelen kan dan berekend worden door de formule

$$P_{PV}(t) = P_{Peak} \left(\frac{G(t)}{G_{standard}} \right) - \alpha_T [T_c(t) - T_{standard}]$$

waarbij $G_{standard}$ en $T_{standard}$ verwijzen naar de standaard testcondities die fabrikanten van zonnepanelen hanteren (Kazem & Yousif, 2017). Deze standaard test condities zijn 1000 W/m^2 zonnestraling en een omgevingstemperatuur van 25°C .

P_{peak} verwijst naar het piekvermogen van de zonnepanelen. Dit piekvermogen(Wp) wordt onder bovenstaande omstandigheden door de fabrikant bepaald.

α_T verwijst naar de temperatuur-coëfficiënt. Deze waarde geeft aan wat de invloed is van de temperatuur van de zonnepanelen op het rendement van de zonnepanelen. De meeste zonnepanelen hebben een temperatuurcoëfficiënt van ongeveer $-0,35\%$ per graad Celsius. Dat betekent dat het vermogen ongeveer met 1% afneemt bij een stijging van 3 graden Celsius.

T_c tenslotte verwijst naar de zonneceltemperatuur en word berekend via volgende fomule:

$$T_c(t) - T_{ambient} = \frac{T_{standard}}{800} G(t)$$

De PV-installatie die voor dit onderzoek gebruikt werd, bestaat uit 10 zonnepanelen die elk een piekvermogen van 215 Watt hebben. Dit geeft een totaal piekvermogen van 2.150 Watt. Zonnepanelen behalen echter nooit hun volledige piekvermogen omdat de weers- en omgevingsfactoren anders zijn dan de bovenvermelde standaard testcondities die door de fabrikanten gebruikt worden. In België moet rekening gehouden worden met een omgevingsfactor van 0,85. Dit betekent dat het werkelijke piekvermogen van de zonnepanelen slechts 1.827,50 Watt is ($2.150 \text{ Watt} \times 0,85$). De zonnepanelen die in dit onderzoek gebruikt werden, zijn echter al 25 jaar oud en uit de metingen gedurende anderhalve maand blijkt dat zij nog maar 76% van hun piekvermogen halen, zijnde 1.634 Watt.

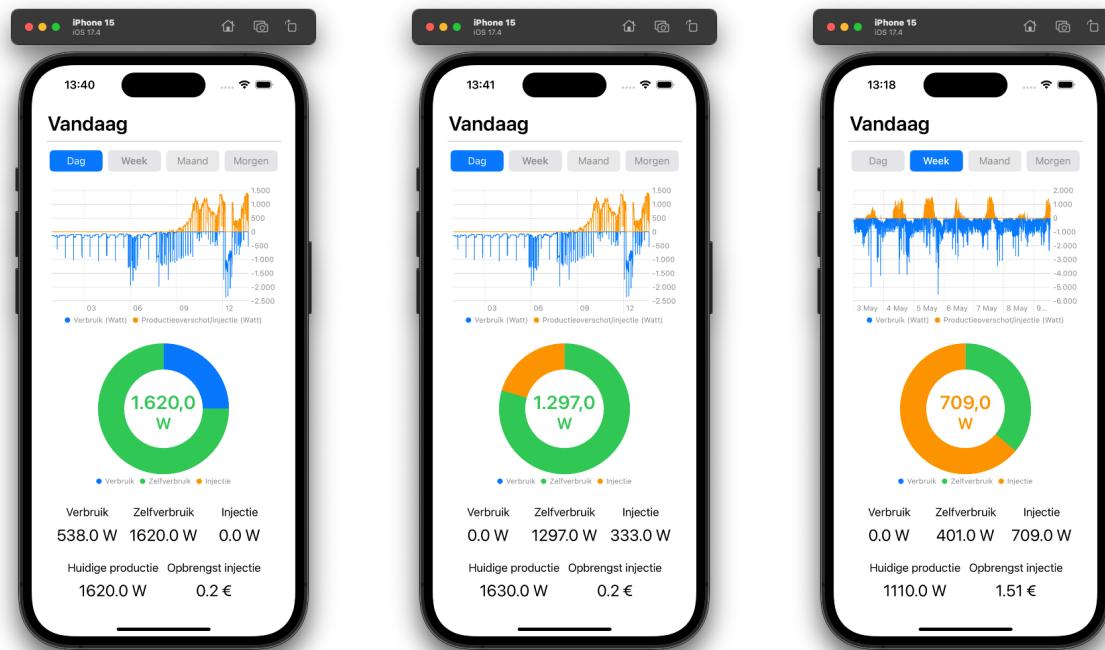
4.1.4. Weergave uitgelezen data en voorspelling met een iOS app

Omdat een smartphone makkelijker en vaker consulteerbaar is, werd in dit onderzoek geopteerd voor de ontwikkeling van een mobiele app om de elektriciteitsconsumptie- en productie weer te geven en op te volgen. De app is ontwikkeld voor iOS omdat dit het testen achteraf vergemakkelijkt. De iOS-app werd gebouwd in de geïntegreerde ontwikkelomgeving (IDE) XCode met SwiftUI en UIKit. Voor documentatie en tutorials werd gebruik gemaakt van het [Apple developer platform](#).

Om de uitgelezen data van de digitale elektriciteitsmeter en de omvormer van de zonnepanelen beschikbaar te maken voor de app, werd eerst een webserver geïnstalleerd op de Raspberry Pi. Daarvoor werd Flask gebruikt. Dit is een open-source Python web framework, waarmee op een eenvoudige manier webapplicaties gebouwd kunnen worden. Het is een micro-framework wat betekent dat het weinig tot niet afhankelijk is van externe libraries en zeer licht is. Omdat de backend voor de ontwikkelde app eerder beperkt is en de webserver op een minicomputer moet draaien, is Flask de meest voor de hand liggende keuze (Shokrzad, 2023). Met de toevoeging van één enkel bijkomend Python bestand konden alle nodige REST-calls opgezet worden.

Elektriciteitsconsumptie en -productie

De ontwikkelde app geeft de gebruiker vooreerst een overzicht van zijn of haar elektriciteitsverbruik- en productie.



Figuur (4.9)

Overzicht elektriciteitsverbruik en -productie per dag en per week.

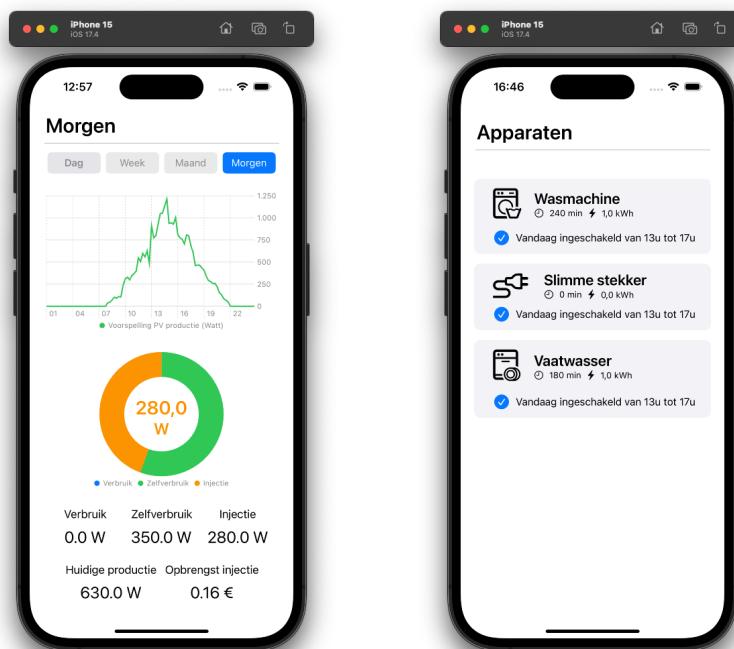
Op een eerste grafiek worden per periode (dag, week, maand) het verbruik en productieoverschot getoond. Dit productieoverschot is de zelf geproduceerde stroom die niet verbruikt wordt en dus in het distributienetwerk geïnjecteerd wordt. Voor deze injectie ontvangt de gebruiker een beperkte vergoeding van zijn of haar stroomleverancier. Het doel van het onderzoek van deze bachelorproef is niet enkel om het elektriciteitsverbruik beter te gaan spreiden, maar ook om ervoor te zorgen dat de zelf geproduceerde stroom van de zonnepanelen effectief zelf verbruikt wordt. Het bedrag van de vergoeding voor de geïnjecteerde stroom is immers dermate laag dat het financieel voordeliger is om de zelfgeproduceerde elektriciteit zelf te gebruiken, dan deze stroom te verkopen. Om die reden wordt het bedrag van de opbrengst van de geïnjecteerde stroom gedurende de geslecteerde periode aan de gebruiker getoond. Zo heeft deze een besef van het voordeel dat zelfverbruik hem of haar oplevert.

Op een tweede grafiek worden de huidige consumptie- en productiegegevens getoond. Zo ziet de gebruiker duidelijk hoeveel elektriciteit hij of zij van het net afneemt en dus betaalt, hoeveel van de zelf opgewekte stroom hij of zij effectief zelf gebruik en hoeveel van de zelfgeproduceerde stroom geïnjecteerd en dus verkocht wordt. Daarbij wordt in het midden van de grafiek de grootste van deze drie waarden getoond, zodat de gebruiker meteen ziet wat er overheerst: zijn of haar verbruik, zelfconsumptie of injectie.

Tot slot worden onder de beide grafieken de consumptie- en productiedetails als waarden getoond. Zo ziet de gebruiker ook de totale hoeveelheid elektriciteit die door de zonnepanelen wordt opgewekt.

Voorspelling stroomproductie

Via de app kan ook de voorspelde stroomproductie van de volgende dag geraadpleegd worden. Deze voorspelling is het resultaat van het Python script waarmee het XGBoost algoritme en de voorspelling van de stroomproductie geïmplementeerd werd. Dit script wordt automatisch om het uur uitgevoerd, zodat steeds een recente voorspelling kan getoond worden. De gemaakte voorspelling wijzigt immers doorheen de dag. Het is op basis van deze voorspelling dat de app automatisch sanitair of andere apparaten zal gaan inschakelen wanneer er voldoende stroomproductie voorspeld wordt.



Figuur (4.10)

Voorspelling van de stroomproductie en overzicht van de ingeschakelde apparaten.

4.1.5. Aansturing slimme apparaten op basis van de voorspelde stroomproductie

De gebruiker zal via de app toestellen kunnen toevoegen die automatisch ingeschakeld mogen en kunnen worden wanneer er voldoende stroomproductie voorspeld wordt. De app zal de gebruiker adviseren over welke apparaten het best kunnen worden toegevoegd omdat ze het meeste verbruiken. Denk daarbij in de eerste plaats aan een warmtepomp of laadpaal indien deze aanwezig zijn, maar ook aan de wasmachine en de vaatwasser. De app zal zelf het verbruik en de inschakelduur van het apparaat gaan bepalen. Indien bijvoorbeeld een wasmachine wordt toegevoegd, dan zal de app het verbruik instellen op 1 kWh en ervan uitgaan dat een wasprogramma gemiddeld 3 uur duurt. De gebruiker zal evenwel de mogelijkheid hebben om dit verbruik en de inschakeltijd zelf te gaan instellen, net zoals hij de mogelijkheid heeft om de inschakeling van een apparaat handmatig te verhinderen.

Wanneer uit de voorspelling van de stroomproductie blijkt dat er voldoende elektriciteit zal worden opgewekt de volgende dag, zal de app de toestellen die de gebruiker heeft toegevoegd gaan inplannen voor de volgende dag. Dit was althans de theorie, want bij de selectie van de toestellen voor dit onderzoek bleek dat de toestellen van het huis dat als testopstelling diende nog niet 'slim' waren. Een probleem dat zich helaas zal voordoen bij heel wat gezinnen. Om dit op te vangen

werd gebruik gemaakt van slimme stekkers. Dit zijn stekkers die via wifi kunnen in- en uitgeschakeld worden. Zij worden tussen het klassieke stopcontact en de stekker van het toestel geplaatst, waardoor een toestel op een eenvoudige manier slim kan gemaakt worden (de Jong, 2020). Maar ook daarbij stelde zich een probleem. Een slimme stekker kan enkel stroom doorlaten of tegenhouden. Dit vereist dat een toestel reeds kan ingeschakeld worden indien het geen stroom krijgt en dat het dus zonder tussenkomst van een gebruiker kan opstarten van zodra de slimme stekker stroom doorlaat. De sanitaire toestellen van de testopstelling voor dit onderzoek, konden pas worden aangezet nadat ze stroom kregen én op een elektronische startknop geduwd werd.

Om de werking van de app in combinatie met slimme stekkers toch te testen, werd een slimme stekker verbonden met een staande lamp. Op die manier kan duidelijk worden waargenomen wanneer de slimme stekker was ingeschakeld. De aansturing van de slimme stekker gebeurt via een Python script dat als een service op de Raspberry Pi minicomputer uitgevoerd wordt. In dit script wordt de slimme stekker bestuurd met behulp van een Python library PyP100 die speciaal ontwikkeld werd voor het gebruikte merk van stekker. Via deze library kan verbinding gemaakt worden met de slimme stekker door het IP-adres en de inloggegevens mee te geven.

```

1  from dotenv import load_dotenv
2  from PyP100 import PyP100
3  from datetime import datetime, timedelta
4  from xgboost_forecast import prediction
5  import os
6
7  # Loading variables from .env file
8  load_dotenv()
9
10 # Define moments of time
11 current_hour = datetime.now().hour
12 tomorrow = (datetime.now() + timedelta(days=1)).day
13
14 # Connect to smart plug 1
15 smart_plug_1 = PyP100(os.getenv("SMART_PLUG_1_IP_ADDRESS"),
16                      os.getenv("SMART_PLUG_USERNAME"),
17                      os.getenv("SMART_PLUG_PASSWORD"))
18
19 # Activate device when PV power reaches 800 Watts
20 start_time = prediction.loc[(prediction['final_prediction'] > 800) &
21                             (prediction.index.day == tomorrow)].head(1).index.hour[0]
22 delay = start_time * 3600
23 duration = 3 * 3600
24
25 while True:
26     if (current_hour == (start_time)):
27         smart_plug_1.turnOnWithDelay(delay)
28         smart_plug_1.turnOffWithDelay(duration)
```

Figuur (4.11)

Screenshot van de Python code om de slimme stekker aan te sturen op basis van de voorspelde stroomproductie.

Het script is zo geprogrammeerd dat het elke dag om 23u zal uitgevoerd worden. Het vraagt daarbij eerst de voorspelling van de stroomproductie van de volgende dag op. Vervolgens zal de slimme stekker geprogrammeerd worden om de volgende dag in te schakelen van zodra de voorspelde waarde van de opgewekte stroom 800 Watt of meer bedraagt. Op de dag zelf kan de gebruiker in de app een overzicht kunnen raadplegen van de ingeschakelde apparaten met hun tijdschema.

5

Conclusie

A

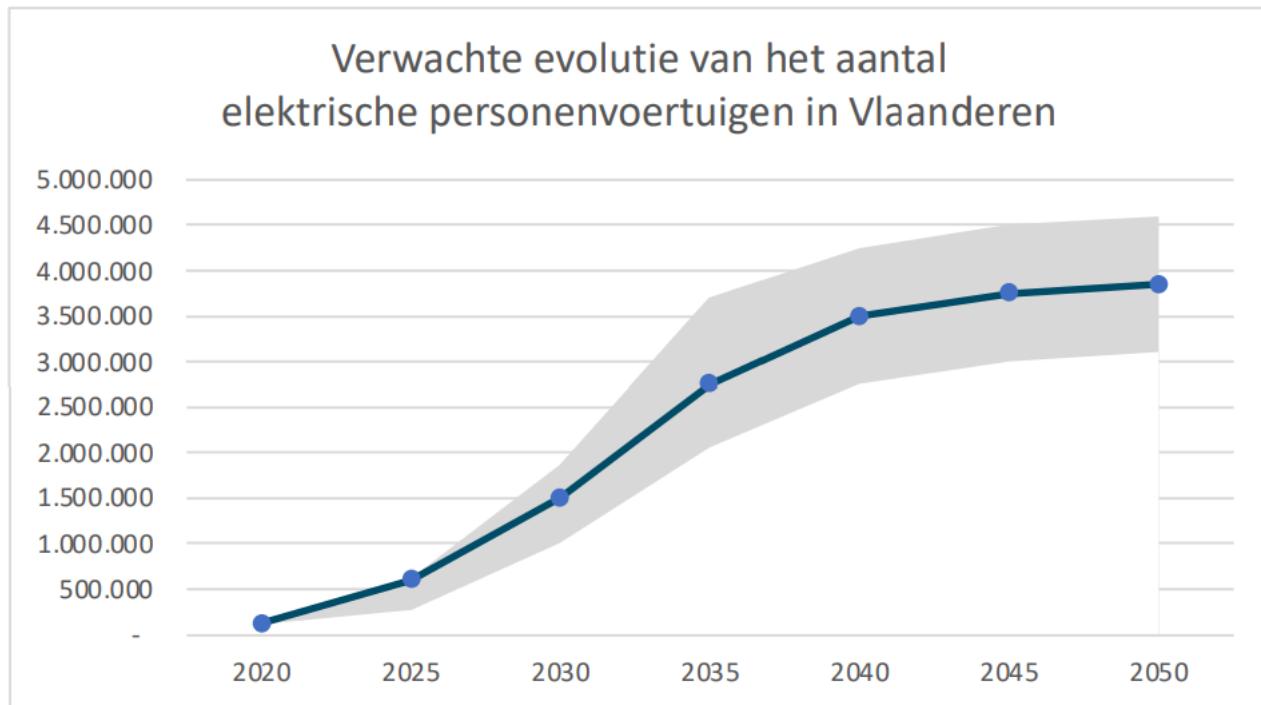
Onderzoeksvoorstel

Samenvatting

Het doel van dit onderzoek is te achterhalen hoe het elektriciteitsverbruik van gezinnen automatisch kan worden bijgestuurd en gespreid met behulp van artificiële intelligentie (AI) en een mobiele app die verbonden is met een digitale elektriciteitsmeter en een weer API. Door de omschakeling naar hernieuwbare energie wordt volop ingezet op elektrificatie. Dit vraagt enerzijds een modernisering van het distributienetwerk voor elektriciteit, maar ook de inzet van slimme technologieën, zoals de digitale elektriciteitsmeter. Deze meter kan slim gemaakt worden door er apps mee te verbinden die gezinnen inzicht geven in hun energieverbruik zodat ze dit kunnen bijsturen en spreiden. Hiermee kan het distributienetwerk dan efficiënter gebruikt worden, zodat overdreven investeringen kunnen vermeden worden.

In het eerste deel van het onderzoek zal worden nagegaan welke apps er momenteel bestaan, welke functies ze bieden en wat hun tekortkomingen zijn. De Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG) ([2021](#)) heeft vastgesteld dat het slim maken van digitale elektriciteitsmeters voorlopig niet tot de gewenste gedragsverandering en spreiding van het verbruik van elektriciteit leidt. Het merendeel van deze apps geeft immers enkel op een passieve manier inzicht in het elektriciteitsverbruik en laat de bijsturing ervan over aan de gebruiker.

In het tweede deel van dit onderzoek zal daarom een app ontwikkeld worden die met behulp van artificiële intelligentie en een weer API het elektriciteitsverbruik automatisch en dus actief zal bijsturen en spreiden. Meer concreet zal AI worden gebruikt om voorspellingen te doen op basis van historische verbruiksdata die dan gecombineerd worden met weersvoorspellingen die verkregen worden via een weer-

**Figuur (A.1)**

Verwachte evolutie van het aantal elektrische personenvoertuigen in Vlaanderen (Verdoodt, 2022).

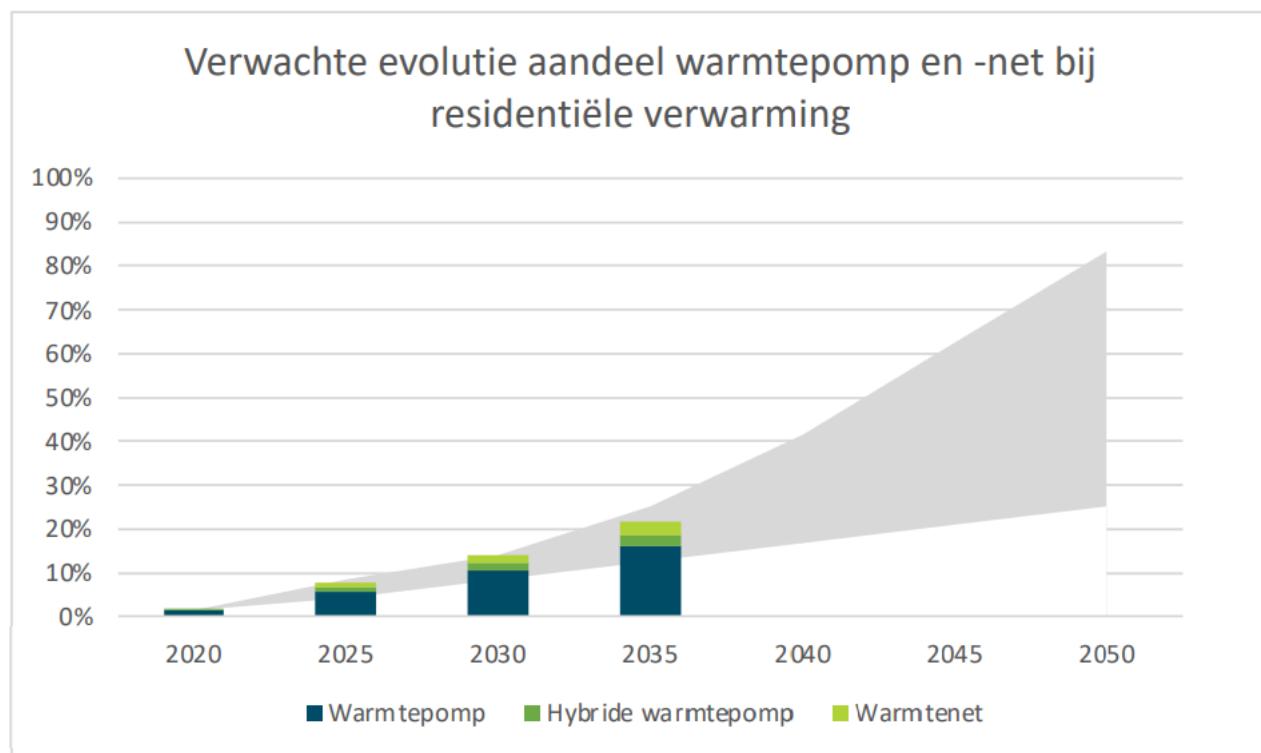
API. De app zal dan op basis van de gecombineerde voorspellingen een warmtepomp en sanitaire toestellen automatisch gaan in- of uitschakelen. Daarbij zal de gebruiker wel nog steeds de mogelijkheid geboden worden om manueel tussen te komen.

Het verwachte resultaat is dat het elektriciteitsverbruik op die manier wel meer gestuurd en gespreid zal worden. Dit zal niet alleen tot een ontlasting van het distributienetwerk voor elektriciteit leiden, maar zal ook de energiekosten voor de gezinnen drukken.

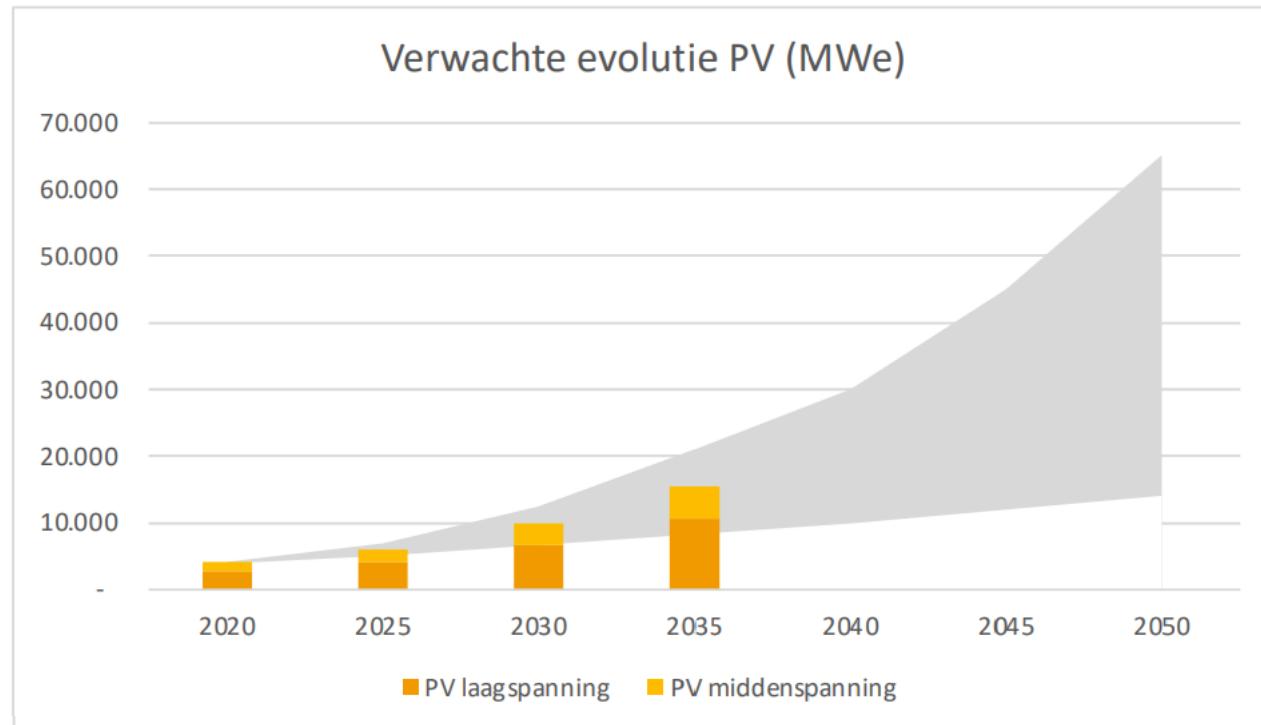
A.1. Inleiding

Anderhalf miljoen elektrische wagens, massaal veel warmtepompen en zonnepanelen gecombineerd met een toenemende elektrificatie van de industrie en het vrachtvervoer tegen 2030. Dat is de verwachting van de Vlaamse distributienetbeheerder Fluvius (Verdoodt, 2022). De energietransitie die vanuit Europa, België en Vlaanderen wordt aangestuurd, vormt een enorme uitdaging voor de distributienetten voor elektriciteit in Vlaanderen.

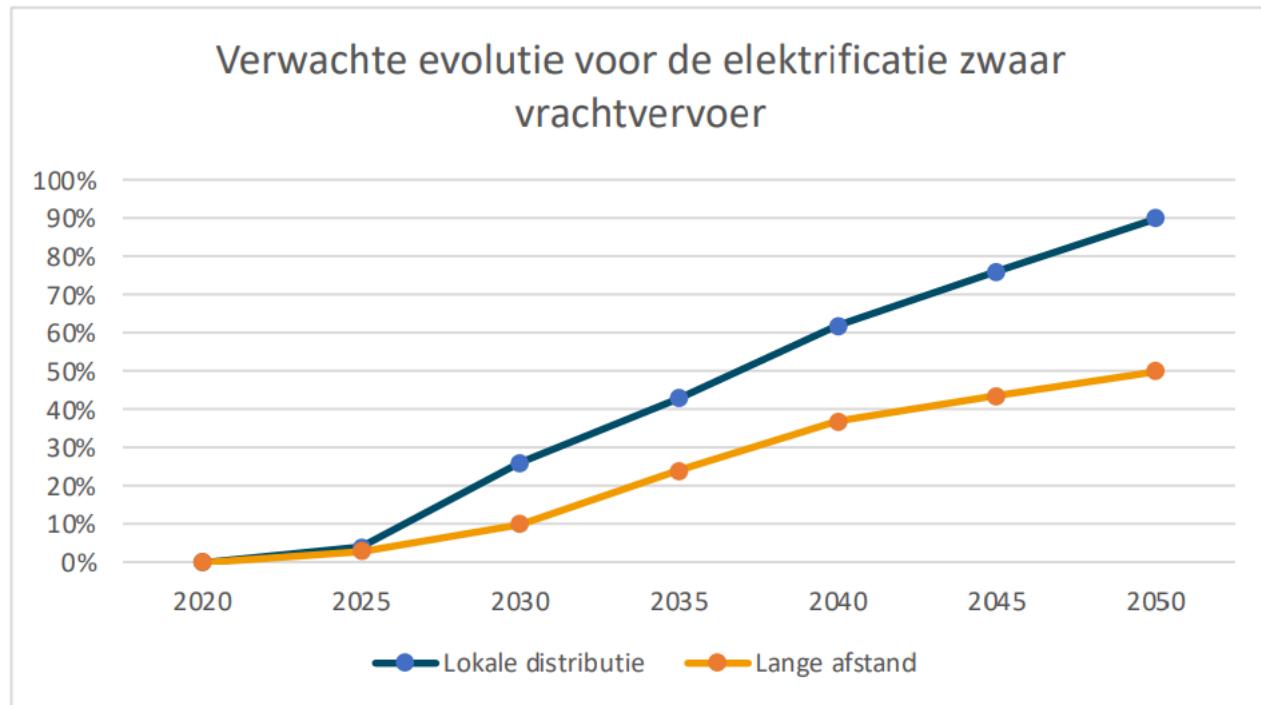
Om al te hoge investeringen in de distributienetten te vermijden, wordt door Fluvius ingezet op maatregelen die de belasting van het elektriciteitsnet kunnen verminderen en spreiden. Een van die maatregelen is de invoering en verplichting van de digitale elektriciteitsmeter. Tegen juli 2029 moeten alle Belgische huishou-

**Figuur (A.2)**

Verwachte evolutie aandeel warmtepomp en -net bij residentiële verwarming (Verdoodt, 2022).

**Figuur (A.3)**

Verwachte evolutie PV (MWe) (Verdoodt, 2022).

**Figuur (A.4)**

Verwachte evolutie voor de elektrificatie zwaar vrachtvervoer (Verdoodt, 2022).

dens een digitale meter hebben. Deze digitale meters kunnen via een dongle en een app 'slimmer' gemaakt worden, zodat gezinnen hun elektriciteitsverbruik in detail kunnen opvolgen en bijsturen. Dit zal dan meteen ook een besparing voor hen opleveren. Deze apps vereisen echter steeds een actieve opvolging van de gebruiker. Uit onderzoek is gebleken dat deze actieve bijsturing na verloop van tijd verminderd (Wemyss e.a., 2019). Een enquête van de Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG) (2021) waarin 1.000 Vlaamse gezinnen en 1.500 bedrijven bevraagd werden over hun ervaring en gedrag op de energemarkt toont zelfs aan dat van de 60% van de gezinnen met een digitale meter, slechts 8% hun energieverbruik effectief bijstuurt. Door de invoering van het capaciteitstarief, een andere maatregel waarmee de VREG het elektriciteitsnet hoopt te ontlasten, zal de bijsturing en vooral spreiding van het elektriciteitsverbruik nog belangrijker worden voor gezinnen. Sinds 1 januari 2023 wordt immers een deel van de nettarieven die een gezin via haar elektriciteitsfactuur betaalt ook berekend op het maximale elektriciteitsverbruik. Er wordt dus voortaan ook gekeken naar de maximale capaciteit die de distributienetbeheerders ter beschikking moeten stellen. Bedoeling van het capaciteitstarief is dat gezinnen hun stroomverbruik beter gaan spreiden. Als iedereen op hetzelfde moment veel stroom verbruikt, kan het net overbelast raken. Het gevolg is dat netbedrijven dan extra moeten investeren in zwaardere elektriciteitskabels om die hogere verbruikspieken op te vangen (Selleslagh, 2022).

Daarom wordt binnen Fluvius de vraag gesteld hoe nieuwe technologieën en tech-

nieken een oplossing kunnen bieden om gezinnen te helpen bij het spreiden van hun elektriciteitsverbruik. Kunnen apps die het elektriciteitsverbruik monitoren slimmer gemaakt worden zodat ze geen tussenkomst van een gebruiker meer behoeven? Kan bijvoorbeeld artificiële intelligentie (AI) daarbij een oplossing bieden? Om dit na te gaan, zal tijdens dit onderzoek een app ontwikkeld worden die het elektriciteitsverbruik zal aansturen op basis van weersvoorspellingen en historische verbruiksdata.

A.2. Literatuurstudie

Met een digitale elektriciteitsmeter kunnen gezinnen hun elektriciteitsverbruik makkelijk opvolgen. Dat kan in de eerste plaats gratis via het online energieportaal [Mijn Fluvius](#). Daarnaast bestaan er ook heel wat gratis of betalende online apps die op de gebruikerspoort van de digitale meter kunnen worden aangesloten om elektriciteitsverbruik op te volgen en de mogelijkheid bieden om andere toestellen aan te sturen. Een overzicht van deze toepassingen vindt men op de website [www.maakjemeterslim.be](#).

De digitale elektriciteitsmeter heeft twee gebruikerspoorten waar verschillende toestellen aan kunnen worden gekoppeld. Beide gebruikerspoorten zijn complementair en geschikt voor verschillende toepassingen. De P1-poort stuurt de elektriciteitsdata per seconde rechtstreeks uit. Via de 'snelle' S1-poort worden ruwe data aan een hoge frequentie ter beschikking gesteld. Beide poorten laten gedetailleerde verbruikersfeedback en sturing van huishoudapparaten toe. Op de gebruikerspoorten (P1 en/of S1) kan een energiebeheersysteem worden aangesloten (Depuydt, 2021). Concreet gaat het om apps, slimme thermostaten of andere toestellen waarmee men elektriciteitsverbruik actief kan beheren. Zo'n toepassingen heten in het jargon 'HEMS' (Home Energy Management System) of 'CEMS' (Customer Energy Management System). De verbinding tussen het meettoestel en een app gebeurt in de meeste gevallen via een wifiverbinding of 4G.

De bestaande apps bieden allemaal de mogelijkheid om elektriciteitsverbruik in real time op te volgen. In elf gevallen kan dat naast een overzicht op de smartphone, tablet of computer ook via een afzonderlijk beeldscherm op de muur. Het meten van de energiekosten per huishoudtoestel behoort standaard tot verschillende apps, maar geldt ook vaak als een optie. De meeste apps sporen ook sluipverbruik op en bieden gepersonaliseerde tips voor energiebesparing. Sommige apps bieden tenslotte ook de mogelijkheid om het gemeten elektriciteitsverbruik naast weerdata te leggen en op die manier na te gaan hoeveel stroom men verbruikt bij bepaalde weersomstandigheden (Deman, 2021). Het is duidelijk dat al deze apps slechts op een passieve het elektriciteitsverbruik van de gebruiker bijsturen. Het is de gebruiker zelf die op basis van de gegevens die de app hem toont actie kan

ondernemen. En hoewel sommige bestaande apps efficiënter dan andere blijken (Mack & Tampe-Mai, 2016) en (Wood, 2019), leidt dit zoals reeds eerder werd vermeld, niet altijd tot de gewenste gedragsverandering (Wemyss e.a., 2019), (Mack e.a., 2019) en (Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG), 2021).

Omdat het noodzakelijk is dat gezinnen en bedrijven bewuster en actiever met hun energieverbruik gaan omspringen, wordt binnen Fluvius en ook andere bedrijven gekeken naar nieuwe technologieën en technieken (Verdoodt, 2018). Dit bracht mij op het idee om een app te gaan ontwikkelen die wel actief en dus automatisch het elektriciteitsverbruik kan gaan bijsturen. Omdat er reeds apps bestaan die weerdata gebruiken om het elektriciteitsverbruik onder bepaalde weersomstandigheden in kaart te brengen, lijkt het me zeker mogelijk om weerdata ook als aansturing te gaan gebruiken, samen met de historieken van het elektriciteitsverbruik om dan zo het toekomstig elektriciteitsverbruik en de elektriciteitsproductie te voorspellen (Guo e.a., 2022). Er zijn tal van bestaande gratis weer API's, zoals [Open Weather Map](#) of [Weather API](#) die kunnen geïntegreerd worden in een app. Om de voorspellingen zo accuraat mogelijk te maken, zal gebruik gemaakt worden van het Extreme Gradient Boosting (XGBOOST) algoritme (Ledmaoui e.a., 2023), (Wang e.a., 2022) en (Barrera-Animas e.a., 2022). De historische verbruiksdata, de productiedata van de omvormer van de zonnepanelen en de weerdata zullen als input gebruikt worden voor dit algoritme. De data van de digitale elektriciteitsmeter en de omvormer van de zonnepanelen wordt continue uitgelezen met een python script op een Raspberry Pi computer die via het wifi-netwerk verbonden is. Deze data wordt opgeslagen in een NoSQL-databank die speciaal voor time-series ontwikkeld is, nl. InfluxDB (Balis e.a., 2017) en (Struckov e.a., 2019). De app zal tenslotte ontwikkeld worden voor iOS en gebouwd worden met Xcode, SwiftUI en UIKit (Allardice e.a., 2023) en (Firtman, 2022).

De eerste slimme toestellen die via de app zullen worden beheerd zijn zonnepanelen en een warmtepomp (Uytterhoeven e.a., 2019). Door de afschaffing van de virtueel terugdraaiende teller voor eigenaars van zonnepanelen, waarbij de teller van de elektriciteitsmeter terugdraait wanneer meer elektriciteit wordt opgewekt dan verbruikt, kan het verlies van dit voordeel opgevangen door het verbruik van de warmtepomp te laten samenvallen met de productiemomenten van de zonnepanelen (Selleslagh, 2021). Wanneer echter uit de weersverwachtingen blijkt dat er een aanzienlijke elektriciteitsproductie zal zijn, zal de app mede op basis van historiek van het elektriciteitsverbruik automatisch ook andere toestellen, zoals de vaatwas of wasmachine gaan inschakelen. Om de sanitaire toestellen te kunnen gaan inschakelen, zal in de eerste plaats gekeken worden of deze toestellen van zichzelf reeds slim zijn. Meer concreet zal geverifieerd worden of ze over een Soft Real Time Operating System beschikken (Soft RTOS) en via het wifinetwerk kun-

nen communiceren met een app. Voor de sanitaire toestellen die niet slim zijn, zal gebruik gemaakt worden van slimme stopcontacten. Daarbij wordt er tussen het klassieke stopcontact en de stekker van het toestel een apparaat geplaatst, waardoor een toestel op een eenvoudige manier slim kan gemaakt worden (de Jong, 2020).

A.3. Methodologie

Het onderzoek zal aangevat worden met een studie van bestaande apps die kunnen verbonden worden met een digitale elektriciteitsmeter en waarmee elektriciteitsverbruik kan opgevolgd en beheerd worden. Er bestaan heel wat gratis apps die elektriciteitsverbruik kunnen visualiseren en aansturen. Bedoeling is om een aantal van deze apps uitvoerig te gaan bestuderen. Wat zijn de functies die ze bieden. Hoe visualiseren deze apps het elektriciteitsverbruik en op welke manier kan het verbruik bijgestuurd worden. Door deze studie kan worden aangetoond dat de meeste van de apps om elektriciteitsverbruik te beheren louter passief werken en steeds een actie van de gebruiker vereisen.

In het tweede deel van het onderzoek zal een app ontwikkeld worden die met behulp van artificiële intelligentie historische verbruiksdata en weersvoorspellingen zal gebruiken om het elektriciteitsverbruik automatisch aan te sturen en te beheren. Vooreerst zal de data van de digitale elektriciteitsmeter worden uitgelezen met behulp van een Raspberry Pi 2GB. De uitgelezen data zal worden opgeslagen in een Azure databank. Wanneer voldoende verbruiksdata verzameld is, zal artificiële intelligentie gebruikt worden om toekomstig elektriciteitsverbruik te voorspellen. Daarvoor zal in eerste instantie gekeken worden naar een bestaand AI platform zoals Azure AI van Microsoft. Om de voorspelling nog accurater te kunnen maken, zal de historische verbruiksdata gecombineerd worden met weersvoorspellingen van een open source weer API. De voorspellingen zullen vervolgens gebruikt worden om slimme of slim gemaakte toestellen automatisch te gaan in- of uitschakelen. Om dit alles inzichtelijk te maken voor de gebruiker zal een mobiele applicatie in IOS ontwikkeld worden. Via deze mobiele applicatie zal de gebruiker ook de mogelijkheid hebben om handmatig bij te sturen indien hij of zij dit wenst.

Nadat de app ontwikkeld is, zal een selectie worden gemaakt van welke elektrische toestellen de app zal aansturen. Er zal nagegaan worden met welke toestellen het meeste elektriciteit bespaard kan worden door ze met weersvoorspellingen aan te sturen. Verder zal ook bepaald worden op welke manier de gekozen toestellen slim kunnen gemaakt worden. Zijn de toestellen reeds slim van zichzelf, zoals bijvoorbeeld sommige zonnepanelen dat zijn, of moeten de toestellen slim gemaakt worden? Een optie daarbij is het gebruik van slimme stopcontacten. Daarbij kan er tussen het klassieke stopcontact en de stekker van het toestel een apparaat geplaatst worden, waardoor een klassiek stopcontact zonder ingrijpende werken slim kan gemaakt worden.

Om na te gaan of de app een elektriciteitsbesparing oplevert, zullen een aantal testgebruiker de app gedurende een maand testen. Om de werking van de app te kunnen testen zullen vijf testgebruikers geselecteerd worden. Zij zullen de app ge-

durende een maand gebruiken. In de eerste plaats zal de testgebruikers gevraagd worden om elke dag na te gaan of en wanneer de verbonden slimme toestellen door de app aangestuurd werden. In de app zal namelijk steeds een overzicht van de in- en afschakelmomenten van de verschillende toestellen beschikbaar zijn. Daarnaast zullen de testgebruikers ook gevraagd worden om een manuele bijsturing te noteren en kort de reden hiervan te vermelden. Telkens wanneer de app een verbonden toestel niet correct in- of uitschakelt, kan de gebruiker tussenkomsten en het desbetreffende toestel zelf in- of uitschakelen. Na afloop van deze onderzoeks-fase zullen vijf testgebruikers, waaronder de onderzoeker zelf, de app gedurende een maand getest hebben.

Na de testperiode zal worden geverifieerd in welke mate de app de ermee verbonden apparaten correct heeft in- en uitgeschakeld. Meer concreet zal worden nagegaan hoe vaak de door de app aangestuurde toestellen correct werden in- of uitgeschakeld. Daarvoor zullen de door de app geregistreerde gegevens vergeleken worden met de door de testgebruikers genoteerde manuele tussenkomsten. Ook zal de testgebruikers een vragenlijst worden voorgelegd, waarin naar hun ervaringen met het gebruik van de app gepeild wordt. Zo zal er gevraagd worden of de app op de juiste momenten de ermee verbonden toestellen in- en uitschakelde. Er zal een verslag worden opgemaakt waarin per testgebruiker en per toestel de manuele bijsturingen in kaart worden gebracht. Hieraan zullen ook de antwoorden op de vragenlijst worden toegevoegd, zodat per testgebruiker een conclusie kan getrokken worden.

A.4. Verwachte resultaten

De verwachting is dat na afloop van dit onderzoek de zelfconsumptie van de test-deelnemers verhoogd is en het elektriciteitsverbruik meer gespreid wordt. Om hieruit ook werkelijk een financieel voordeel te halen, zal de minstens 50% zelfverbruik moeten behaald worden (Selleslagh, 2021). Als naast de warmtepomp ook een wasmachine, vaatwasmachine en een elektrisch voertuig kunnen worden aangesloten op de ontwikkelde app, zal dit percentage zeker behaald kunnen worden.

Omdat ook piekverbruiken moeten vermeden worden omwille van het capaciteits-tarief, zal de app enkel toestellen inschakelen indien de elektriciteit die door de zonnepanelen gegenereerd wordt toereikend is om aan het gecombineerde verbruik te voldoen. Op basis van de weersverwachtingen zal de app gaan inschatten of de productie voldoende lang kan gegarandeerd worden. Zo zullen meerdere toestellen tegelijkertijd kunnen worden ingeschakeld zonder een verbruikspiek te veroorzaken. Omgekeerd zal de app er ook voor zorgen dat op dagelijkse piekmo-menten sommige toestellen worden uitgeschakeld, indien er onvoldoende elektri-citeit wordt opgewekt door de zonnepanelen. Zo zal de warmtepomp uitgescha-

keld worden op het moment dat al veel andere apparaten aan het werk zijn. Verwacht wordt dat de app de piekverbruiken zo automatisch tot een minimum zal herleiden, waardoor de nettarieven en dus de elektriciteitsfactuur voor gezinnen kan verlaagd worden.

Bibliografie

- Ahmad, M. W., Reynolds, J., & Rezgui, Y. (2018). Predictive modelling for solar thermal energy systems: A comparison of support vector regression, random forest, extra trees and regression trees. *Journal of Cleaner Production*, 203, 810–821. <https://doi.org/https://doi.org/10.1016/j.jclepro.2018.08.207>
- Allardice, S., Bancroft, A., Ferrone, H., Moeykens, M., Nutter, D., Nyisztor, K., & Wong, J. (2023, mei 24). *iOS App Development - Fundamentals*. Pluralsight. Verkregen mei 24, 2023, van <https://www.pluralsight.com/paths/ios>
- Balakumar, P., Vinopraba, T., & Chandrasekaran, K. (2023). Machine learning based demand response scheme for IoT enabled PVintegrated smart building. *Sustainable Cities and Society*, 89. <https://doi.org/https://doi.org/10.1016/j.scs.2022.104260>
- Balis, B., Bubak, M., Harezlak, D., Piotr, N., Pawlik, M., & Wilk, B. (2017). Towards an operational database for real-time environmental monitoring and early warning systems. *Procedia Computer Science*, 108, 2250–2259. <https://doi.org/https://doi.org/10.1016/j.procs.2017.05.193>
- Barrera-Animas, A. Y., Oyedele, L. O., Bilal, M., Akinosho, T. D., Delgado, J. M. D., & Adewale Akanbi, L. (2022). Rainfall prediction: A comparative analysis of modern machine learning algorithms for time-series forecasting. *Machine Learning with Applications*, 7(100204). <https://doi.org/https://doi.org/10.1016/j.mlwa.2021.100204>
- Brownlee, J. (2023, oktober 23). *Supervised and Unsupervised Machine Learning Algorithms*. Machine Learning Mastery. Verkregen april 30, 2024, van <https://machinelearningmastery.com/supervised-and-unsupervised-machine-learning-algorithms/>
- de Jong, D. (2020, mei 16). Upgrade je stopcontact: 15 slimme stekkers getest. Hardware Info. Verkregen mei 3, 2023, van <https://be.hardware.info/artikel/9945/upgrade-je-stopcontact-15-slimme-stekkers-getest>
- Deman, K. (2021, augustus 4). Hoe maak je een digitale meter slim? Mijnenergie. Verkregen mei 15, 2023, van <https://www.mijnenergie.be/blog/hoe-maak-je-een-digitale-meter-slim/#:~:text=De%20website%20www.maakjemeterslim.be,real%20time%20op%20te%20volgen>.
- Depuydt, J. (2021, februari 4). Data lezen van de P1 poort op de Belgische digitale elektriciteitsmeter. Verkregen mei 21, 2023, van <https://jensd.be/1205/linux/data-lezen-van-de-belgische-digitale-meter-met-de-p1-poort>

- Efimov, V. (2024, april 9). *Reinforcement Learning, Part 1: Introduction and Main Concepts: Making the first step into the world of reinforcement learning-* Vyacheslav EfimovTowards Data Science. Towards Data Science. Verkregen april 30, 2024, van <https://towardsdatascience.com/reinforcement-learning-introduction-and-main-concepts-48ea997c850c>
- Firtman, M. (2022, november 21). *How to Choose the Right Mobile App Platform.* Frontend Masters. Verkregen mei 24, 2023, van <https://frontendmasters.com/blog/choosing-mobile-platform/>
- Guo, Z., O'Hanley, J. R., & Gibson, S. (2022). Predicting residential electricity consumption patterns based on smart meter and household data: A case study from the Republic of Ireland. *Utilities Policy*, 79(101446). <https://doi.org/https://doi.org/10.1016/j.jup.2022.101446>
- Jensen, A. R., Anderson, K. S., Holmgren, W. F., Mikofski, M. A., Hansen, C. W., Boeman, L. J., & Roel, L. (2023). pvlib iotools—Open-source Python functions for seamless access to solar irradiance data. *Solar Energy*, 266(112092). <https://doi.org/https://doi.org/10.1016/j.solener.2023.112092>
- Kazem, H. A., & Yousif, J. H. (2017). Comparison of prediction methods of photovoltaic power system production using a measured dataset. *Energy Conversion and Management*, 148, 1070–1081. <https://doi.org/https://doi.org/10.1016/j.enconman.2017.06.058>
- Khasawneh, H. J., Ghazal, Z. A., Al-Khatib, W. M., Al-Hadi, A. M., & Arabiyat, Z. M. (2024). Creating optimized machine learning pipelines for PV power generation forecasting using the grid search and tree-based pipeline optimization tool. *Cogent Engineering*, 11(1). <https://doi.org/https://doi.org/10.1080/23311916.2024.2323818>
- Konsman, M., & Werkman, E. (2023, september 1). *S2 White paper*. Flexiblepower Alliance Network. <https://s2standard.org/>
- Ledmaoui, Y., El Maghraoui, A., El Aroussi, M., Saadane, R., Chebak, A., & Chehri, A. (2023). Forecasting solar energy production: A comparative study of machine learning algorithms. *Energy Reports*, 10, 1004–1012. <https://doi.org/https://doi.org/10.1016/j.egyr.2023.07.042>
- Mack, B., & Tampe-Mai, K. (2016). An action theory-based electricity saving web portal for households with an interface to smart meters. *Utilities Policy*, 42, 51–63. <https://doi.org/https://doi.org/10.1016/j.jup.2016.05.003>
- Mack, B., Tampe-Mai, K., Kouros, J., Roth, F., Taube, O., & Diesch, E. (2019). Bridging the electricity saving intention-behavior gap: A German field experiment with a smart meter website. *Energy Research & Social Science*, 53, 34–46. <https://doi.org/https://doi.org/10.1016/j.erss.2019.01.024>
- Nabatchian, E. (2024, januari 10). *Exploring Time Series Prediction of Energy Consumption Using XGBoost and Cross Validation* (Medium, Red.). Medium. Verkregen mei 8, 2024, van <https://medium.com/@ethannabatchian/exploring-time-series-prediction-of-energy-consumption-using-xgboost-and-cross-validation-5a2a2a2a2a2a>

- [time-series-prediction-of-energy-consumption-using-xgboost-and-cross-validation-5d299655bec6](https://doi.org/https://doi.org/10.1016/j.segan.2023.101256)
- Sahai, N. (2023, september 6). *Random Forest Regression – How it Helps in Predictive Analytics?* AnalyticsLabs. Verkregen april 30, 2024, van <https://www.analytixlabs.co.in/blog/random-forest-regression/>
- Sansine, V., Ortega, P., Hissel, D., & Hopuare, M. (2022). Solar Irradiance Probabilistic Forecasting Using Machine Learning, Metaheuristic Models and Numerical Weather Predictions. *Sustainability*, 14(22). <https://doi.org/https://doi.org/10.3390/su142215260>
- Sehrawat, N., Vashisht, S., & Singh, A. (2023). Solar irradiance forecasting models using machine learning techniques and digital twin: A case study with comparison. *International Journal of Intelligent Networks*, 4, 90–102. <https://doi.org/https://doi.org/10.1016/j.ijin.2023.04.001>
- Selleslagh, D. (2021, april 13). *Zo haalt u toch voordeel uit combinatie van warmtepomp en zonnepanelen.* Netto, De Tijd. Verkregen mei 25, 2023, van <https://www.tijd.be/netto/analyse/vastgoed/zo-haalt-u-toch-voordeel-uit-combinatie-van-warmtepomp-en-zonnepanelen/10297339.html>
- Selleslagh, D. (2022, december 15). *Wat betekent het nieuwe piektarief voor uw stroomfactuur?* Netto, De Tijd. Verkregen mei 15, 2023, van <https://www.tijd.be/netto/dossiers/uw-geld-in-2023/wat-betekent-het-nieuwe-piektarief-voor-uw-stroomfactuur/10434556.html>
- Shokrzad, R. (2023, oktober 27). *Flask vs Django: Deciphering the Best Fit for Your ML Deployment* (Medium, Red.). Medium. Verkregen mei 9, 2024, van <https://medium.com/@reza.shokrzad/flask-vs-django-deciphering-the-best-fit-for-your-ml-deployment-c536dd457a4e>
- Struckov, A., Yufa, S., Visheratin, A. A., & Nasonov, D. (2019). Evaluation of modern tools and techniques for storing time-series data. *Procedia Computer Science*, 156. <https://doi.org/https://doi.org/10.1016/j.procs.2019.08.125>
- Tercha, W., Tadjer, S. A., Chekired, F., & Canale, L. (2024). Machine Learning-Based Forecasting of Temperature and Solar Irradiance for Photovoltaic Systems. *Energies*, 17. <https://doi.org/https://doi.org/10.3390/en17051124>
- Tziolis, G., Lopez-Lorente, J., Baka, M.-I., Koumis, A., Livera, A., Theocharides, S., Makrides, G., & Georghiou, G. E. (2024). Direct short-term net load forecasting in renewable integrated microgrids using machine learning: A comparative assessment. *Sustainable Energy, Grids and Networks*, 37(101256). <https://doi.org/https://doi.org/10.1016/j.segan.2023.101256>
- Uytterhoeven, A., Arteconi, A., & Helsen, L. (2019, mei 24). *De digitale meter en warmtepompen.* KU Leuven. Verkregen april 12, 2023, van <https://lirias.kuleuven.be/retrieve/540231>

- Verdoodt, B. (2018, september 13). *Fluvius lanceert testlabo's voor digitale meters*. Verkregen mei 14, 2023, van <https://pers.fluvius.be/fluvius-lanceert-testlabos-voor-digitale-meters>
- Verdoodt, B. (2022, oktober). *Investeringsplan Fluvius 2023-2032* (tech. rap.). Fluvius. <https://partner.fluvius.be/sites/fluvius/files/2022-06/investeringsplan-2023-2032.pdf>
- Viswa. (2023, juli 31). *Unveiling Decision Tree Regression: Exploring its Principles, Implementation*. Medium. Verkregen april 30, 2024, van <https://medium.com/@vk.viswa/unveiling - decision - tree - regression - exploring - its - principles - implementation-beb882d756c6>
- Vlaamse Regulator van de Elektriciteits- en Gasmarkt (VREG), ((2021). *Marktmonitor 2021* (tech. rap.). VREG. <https://www.vreg.be/sites/default/files/document/rapp-2021-18.pdf>
- Wang, X., Sun, Y., Luo, D., & Peng, J. (2022). Comparative study of machine learning approaches for predicting short-term photovoltaic power output based on weather type classification. *Energy*, 240(122733). <https://doi.org/https://doi.org/10.1016/j.energy.2021.122733>
- Wemyss, D., Cellina, F., Lobsiger-Kägi, E., de Luca, V., & Castri, R. (2019). Does it last? Long-term impacts of an app-based behavior change intervention on household electricity savings in Switzerland. *Energy Research & Social Science*, 47, 16–27. <https://doi.org/https://doi.org/10.1016/j.erss.2018.08.018>
- Wood, W. (2019). *Gelukkig met gewoontes*. HarperCollins Holland.